



UNIVERSIDAD DE MURCIA

FACULTAD DE INFORMÁTICA

TRABAJO FIN DE GRADO

Reconocimiento de emociones mediante EEG y Machine Learning usando Interfaces Cerebro-Máquina

Autor:

Jaime Ortiz Aragón

Supervisores:

Dr. Gregorio Martínez Pérez
Sergio López Bernal

6 de septiembre de 2021

A cada miembro de mi familia, tanto los que viven con nosotros como los que viven en nuestros pensamientos. A mi pareja y amigos por el apoyo constante. A los tutores y directores de proyecto por la ayuda y tiempo prestados. A todos los compañeros y profesores que me han acompañado en esta etapa de mi vida. A todo el mundo que ha invertido tiempo de su vida en hacer la mía mejor estos años. A toda la gente que me sigue y apoya desde distintas partes del mundo. Y, sobre todo, a mí mismo por lo vivido y superado desde el comienzo del Grado.

Índice

	Página
Declaración firmada sobre originalidad del trabajo	v
Resumen	1
Extended Abstract	2
1. Introducción	7
2. Background	9
2.1. Interfaces cerebro-máquina	9
2.2. Fases del ciclo de vida de una interfaz cerebro-máquina	11
2.2.1. Procesamiento	11
2.2.2. Clasificación	12
2.3. Factores biológicos de las emociones humanas.	14
3. Estado del arte	16
3.1. Escenarios de aplicación para la detección de emociones.	16
3.2. Incorporación de sistemas BCI para el reconocimiento de emociones	17
3.3. Bases de datos	18
4. Análisis de objetivos y metodología	22
4.1. Objetivos	22
4.2. Metodología	22
4.2.1. Estudio del estado del arte del caso de uso	23
4.2.2. Estudio de los datasets existentes	23
4.2.3. Procesamiento de los datos contenidos en el dataset seleccionado	23
4.2.4. Entrenamiento de los modelos mediante ML	23
4.2.5. Análisis de los resultados y comparación con el estado del arte	24
5. Diseño y resolución del trabajo realizado	25
5.1. Adquisición de la señal	25
5.2. Preprocesamiento	27
5.3. Extracción de características	27
5.4. Selección de características	28
5.5. Clasificación	28
6. Experimentos realizados	30
6.1. Experimento 1	30

6.2. Experimento 2	30
6.3. Experimento 3	32
6.4. Experimento 4	33
7. Resultados obtenidos	35
7.1. Clasificaciones binarias	35
7.2. Clasificaciones cuaternarias	36
7.3. Comparación con literatura	37
8. Conclusiones	40

Índice de figuras

1.	Silla de ruedas controlada por un sistema de bci [8].	10
2.	Ejemplos de sistemas Brain Computer Interface (BCI) no invasivos.	11
3.	Partes del cerebro humano.	14
4.	Esquema SAM [65]	15
5.	Ejemplo de expresiones faciales mostradas para el reconocimiento de emociones [7].	17
6.	Fases del ciclo de vida de una BCI seguidas en este trabajo.	25
7.	Metodología seguida para el experimento 1 binario.	30
8.	Metodología seguida para los experimentos 2.	31
9.	Metodología seguida para los experimentos 3.	32
10.	Estructura DataFrame con la unión de bandas de frecuencia.	33
11.	Metodología seguida los experimentos 4.	34
12.	Selección de canales del experimento 4 binario.	34

Índice de tablas

1.	Comparativa de trabajos estudiados de la literatura.	21
2.	Columnas del fichero participant_ratings.csv y su descripción.	26
3.	Ajuste de hierparámetros en el experimento 2 binario.	32
4.	Ajuste de hierparámetros en el experimento 2 cuaternario.	32
5.	Ajuste de hierparámetros en el experimento 3 binario.	33
6.	Ajuste de hierparámetros en el experimento 3 cuaternario.	33
7.	Resumen de precisiones en cada uno de los experimentos binarios basadas en la métrica <i>f1_score</i>	36
8.	Resumen de precisiones en cada uno de los experimentos cuaternarios basadas en la métrica <i>f1_score</i>	38
9.	Resumen de precisiones en cada uno de los experimentos.	39

Declaración firmada sobre la originalidad del trabajo

D./Dña. **Jaime Ortiz Aragón**, con DNI **49196689B**, estudiante de la titulación de **Grado en Ingeniería Informática** de la Universidad de Murcia y autor del TFG titulado “**Reconocimiento de emociones mediante EEG y Machine Learning usando Interfaces Cerebro-Máquina**”.

De acuerdo con el Reglamento por el que se regulan los Trabajos Fin de Grado y de Fin de Máster en la Universidad de Murcia (aprobado C. de Gob. 30-04-2015, modificado 22-04-2016 y 28-09-2018), así como la normativa interna para la oferta, asignación, elaboración y defensa de los Trabajos Fin de Grado y Fin de Máster de las titulaciones impartidas en la Facultad de Informática de la Universidad de Murcia (aprobada en Junta de Facultad 27-11-2015)

DECLARO:

Que el Trabajo Fin de Grado presentado para su evaluación es original y de elaboración personal. Todas las fuentes utilizadas han sido debidamente citadas. Así mismo, declara que no incumple ningún contrato de confidencialidad, ni viola ningún derecho de propiedad intelectual e industrial

Murcia, a **06 de septiembre de 2021**



Fdo.: **Jaime Ortiz Aragón**

Autor del TFG

Resumen

Las emociones son fundamentales para los seres humanos y juegan un papel muy importante en el día a día de los mismos. El estado emocional se asocia comúnmente con toma de decisiones lógicas, percepción, interacción humana y, en cierta medida, a la inteligencia humana. Con el desarrollo de las tecnologías y el creciente interés de la comunidad de investigación en establecer algunas interacciones emocionales significativas entre humanos y máquinas, se han desarrollado las conocidas como BCI.

Estos son sistemas de información bidireccionales entre un sujeto y la interfaz. En este trabajo, nos centramos en el caso de uso del reconocimiento de emociones por medio de interfaces cerebro-máquina. Esto requiere de soluciones confiables y desplegables para la identificación de estados emocionales humanos. Recientemente, han habido grandes avances en el uso de la Electroencefalografía (EEG) como método para la adquisición de las señales neuronales.

Este trabajo cubre varios aspectos. Primeramente, trata de explicar qué son las interfaces cerebro máquina y cuál es el proceso que siguen en sus evaluaciones. A continuación, se tratan los factores biológicos de las emociones humanas para ser capaces de evaluar las señales adquiridas. Una vez centrándonos en el caso de uso, trataremos de realizar una revisión histórica acerca del uso de estos sistemas para el reconocimiento de las emociones, atendiendo a la literatura y las metodologías más comunes.

El siguiente paso consiste en diseñar una solución para la detección de emociones usando EEG. Es decir, tener pautado por pasos el ciclo de vida del proceso, con los algoritmos correspondientes. Este diseño queda reflejado en una serie de experimentos que ponen a prueba nuestra solución. En nuestro caso, los experimentos se han realizado sobre la base de datos DEAP, aportando distintas decisiones en la selección de características. Como métodos de evaluación, hemos usado algoritmos de Machine Learning (ML) Random Forest, Support Vector Machine (SVM) y k-Nearest Neighbours (kNN) hemos tratado de clasificar el estado emocional de los sujetos. Los resultados son muy prometedores, ya que hemos llegado a obtener en varios casos precisiones superiores al 90 % de *accuracy*, destacando un 95.80 % de acierto para las evaluaciones binarias y un 92.76 % de acierto en las clasificaciones multiclas.

Extended Abstract

In this day and age, technology has become an indispensable topic. It would not be possible to think about a prosperous society without taking into account what technological evolution brings us.

This becomes even more important when we relate it to medicine and health care. It is more shown with the Covid-19 pandemic when all the effort is focused on developing a successful vaccine, carrying out an efficient infrastructure, and developing a safe environment for humans. This situation has affected the medical aspect of the people as human beings affected by the virus and their emotional state. Fear, ignorance, and lockdowns have caused mental issues in people. A long time ago, it was unthinkable to carry out applications for citizen's mobility or special vaccination passports to be able to fly or even to have a meal at a restaurant.

One reflection of this development is the well-known as BCI. These devices are bidirectional systems used for acquiring neuronal data by using brain signals. One example of this process is neurostimulation. Therefore, it is possible to detect the subject's intentions or emotional state, knowing how to act in consequence. Some of the most common purposes of a BCI are medical issues for patients monitoring. But with the current trends, the using area has widened, leading to other areas such as videogames or mental state decoding.

There exist many types of BCI devices, depending on if they are intracranial or outer cranial. This document focuses on the non-invasive, well-known as EEG. This type of equipment is placed over the subject's scalp.

This document aims to learn to recognize emotions with a BCI based on EEG using ML algorithms. This is particularly called affective computing. It is the branch of computing that relates to, arises from, or influences emotions. With the previously spoken development of technology, BCI hardware is becoming more and more affordable for researchers. These devices work by capturing brain signals, which are the data storage for the emotions' evaluation.

Affective states play an essential role in decision-making and problem-solving. This case study takes advantage of positive affective states to enhance emotional intelligence and later act in consequence with the subject to improve his personal or professional success. Being more self-aware of their emotions can help people manage their mental health and consequently optimize their work performance and get a better life. At this stage of the proceedings is where the BCI systems play an important role. By human-to-machine information, exchanges they help people to understand better their emotions. These EEG-based systems could also enrich people's relationships with their environment by making it easier to know how they feel.

The methodology followed to reach the objective of this document is as follows:

- 1) To study the state of the art related to the recognition of emotions with a BCI based on EEG using ML algorithms. At this point, it is important to get all the possible knowledge about BCI devices in-depth. Earlier, this equipment has been presented, but there is more than knowing its purpose and the appliance areas where they take part in. It is essential to know about previous studies that have to make a path on this topic to mitigate errors and take the most from the research. It also gets paramount to get to know the human brain and how emotions are created. This first stage also provides information about different historical means of analyzing emotions, such as the one presented in this document, SAM. This is an image-based model used for measuring the subject's emotional response to a video. Specifically, there exist one item scales to measure the valence or pleasure or the response (from positive to negative), the arousal perceived (from low to high), and the dominance over the stimulus (from low to high).
- 2) To study the existing datasets. Once we know how the BCI works and how to fit it with the recognition of emotions, it becomes necessary to get to know where to pick up the data, which will be later evaluated. To reach this, it is paramount to research which data have been used in previous investigations, whether they use their datasets or resort to the existing ones. On this document, and due to the difficulties generated from the Covid-19 pandemic, such as the contact between subjects and their use of the same devices, the decision taken was to use an existing dataset. Therefore, it could be easier to compare the results and proposals with other existing research. Particularly, the one used is the DEAP dataset. This is the most popular one used in the state-of-the-art literature with almost 50% among all previous studies. At the same time, it brings us some facilities for the signal's processing as it will be explained in next. The DEAP dataset contains 40 subjects EEG recording, for which each one of the subjects was shown 40 randomly chosen music videos. The BCI hardware consisted of 40 channels, 32 used for the EEG capturing, and the other eight for other proposals such as temperature scanning or eye-tracking. This document focuses on the first 32 channels due to the objective is to process the data extracted using EEG.
- 3) To process the data extracted from the dataset. This process has to do with the two first stages of the BCI process, which correspond to signal acquisition and signal to preprocess. This last stage gets essential information for the noise removal and data artifacts that may deteriorate the evaluation process.

The advantage presented in the dataset choosing decision is that this dataset provides data already preprocessed. The methodology used for this stage is almost always the same: downsampling and using a pass-band filter to enclose frequencies in a decent range of values. The file containing this data is easier to read by using *Python* libraries and provides the labels values to classify emotions in a subsequent stage.

- 4) To train models using ML algorithms. After applying the processing phase, it is ne-

cessary to apply the different stages of ML for the detection of emotions. This step is essential for the completeness of the general objective consisting of classifying the data into labeled emotions using ML algorithms. The procedure to follow begins with the extraction of characteristics from the data and the selection of those that are most relevant, following methodologies set out in the literature to finally apply different algorithms using different Python libraries, such as *sklearn*. In this work, both binary and multiclass classifications have been carried out. On the one hand, it has been tried to distinguish between two emotional states, which are more consistent with the emotion felt by the subject. On the other, an attempt has been made to carry out this classification but with a greater number of emotions, which has allowed us to determine the characteristics of a subject's emotional state.

Binary experiments distinguish between "happy" and "sad" taking into account one of the labels provided by the dataset. In this case, we carried out four experiments as follows. The first one is the most simple, as there is no extraction or selection of the data characteristics. The only processing the data has is the already explained preprocessing and the classification. All experiments' classifications have been carried out with three of the most common algorithms in literature: Random Forest, SVM and kNN. As it was known that with no features evaluation, the results were going to be worse, this experiment was not evaluated for the multiclass scenario.

The three other experiments have been evaluated for both the binary and multiclass scenarios with promising results. In the second research, we did take into account the different frequency bands of data, extracting them from the Short-Time Fourier Transform (STFT) algorithm. In this case, we picked up the frequency ranges explained in the literature as follows. Delta band [1-4]Hz, Theta band [4-8]Hz, Alpha band [8-14]Hz, Beta band [14-30]Hz and Gamma band[30-50]Hz. This experiment helps us to reorganize data and to extract some information about it as to which frequency bands work better for each classifier or each emotion. For both the binary and multiclass classification, it was carried out parameter tuning. Therefore the best model of each subject's data was chosen. For experiment number three, the objective was to evaluate the whole information we had in experiment 2 at the same time. In this way, a frequency bands union was done. Therefore, the data that is being processed this time works as it had 32x5 channels, 32 for each band. Finally, the last experiment is distinguished for carrying out a channel selection. In this case, we compare our selection of channels to one selection brought by the literature.

5) To analyze the results and compare them to the previous state-of-the-art studies. Once the data has been processed and classified, the results have been analyzed for consistency and compared with the equivalent methodologies followed by the literature to identify advantages and weaknesses of our processing, which can be corrected in future works.

To carry out the evaluations of the results obtained in the experiments, we used two

metrics depending on what we want to compare. First, to compare the different methodologies in both binary and quaternary classifications, we are going to make use of the metric *f1_score* of each of the emotions. This is because this value is a measure that takes into account both recall and precision. The second metric corresponds to the accuracy value, which we will use to compare our results with those found in the literature. It is not the one that best reflects how a model works, since it does not work well when classes are unbalanced. But since it is the most frequented in this type of experiment, we need it to compare results.

As was expected due to the lack of processing, this experiment has the lowest accuracy indexes among all experiments done. $69,46 \pm 6,87$ for Random Forest, $55,06 \pm 6,02$ for SVM and $74,69 \pm 6,98$ for kNN. These results close the gap with the literature's ones which are presented in the document.

For the second experiment, better precisions are got with the higher frequency bands (Beta and Gamma) in both the binary and the multiclass. This difference becomes larger with the SVM and kNN classifiers. Standard deviation is also greater in the lowest frequency bands, assuming that evaluation is not as stable. For experiment number three, the three classifiers obtain a remarkable *f1_score*, around 95 % in the binary classification and around 90 % in the multiclass. These values have not been obtained in the presented literature. In the last experiments, both selections present a good score, existing only a big gap when using the SVM algorithm for the multiclass classification, where our selection gets around a 10-15 % increase from the channel selection done in the literature.

As a summary, in this document, we have been focused on the medical and health field to recognize the subjects' emotions. The data with which we have worked have been provided by the DEAP database, and we have tried to follow different methodologies for the recognition of emotions through ML algorithms. On the one hand, we have performed binary classifications in which the Random Forest algorithm has achieved results of +95 % accuracy in three out of four experiments, and both SVM and kNN have also achieved promising results, exceeding 93 % accuracy in most experiments. On the other hand, multiclass experiments have been carried out, which allow us to detect four emotions. In this case, the results provided by Random Forest are once again the best, exceeding 92 % precision and both SVM and kNN exceed 90 % in most experiments. The main contribution of the work carried out consists in the development of different methodologies work related to the life cycle of a BCI, which improve or at least equal the acknowledgments of emotions carried out in the literature.

As future work, one could carry out research that takes into account a broader number of emotions, introduce new methods to extract more characteristics from the data, or put these experiments to use on a BCI setting in which neural signals are captured live. Currently, few studies implement active emotion methods to elicit emotions, such as video

games and flight simulators. In the future, it is proposed that the generation of data sets use methods that actively provoke emotions because these techniques better simulate “real life” events and are more efficient in inducing emotions. However, the implementation of this type of study requires a significantly more complex experimental setup.

1. Introducción

Las tendencias actuales de la tecnología tienen a acercar el mundo de las máquinas al de los humanos, en gran medida, para hacernos más fácil muchas de nuestras tareas cotidianas. Desde la medicina hasta las actividades de ocio, existen dispositivos capaces de influir notoriamente en la vida de las personas. Ejemplos de estas máquinas son las conocidas como BCI. Estas interfaces son canales bidireccionales entre el cerebro de un sujeto y dispositivos externos sobre los que se quiere actuar o con los que se quiere hacer un intercambio de información. Estos dispositivos presentan a grandes rasgos dos usos. Por un lado, pueden usarse para neuroestimular o inhibir la actividad neuronal de un sujeto. Esto puede ser utilizado para tratar enfermedades como el Parkinson, mediante la implantación del dispositivo sobre el cerebro mediante cirugía. Por otra parte, son usadas para monitorizar las señales eléctricas generadas en el cerebro. Estas se distinguen principalmente por el grado de invasividad de la implantación, destacando EEG y Electrocorticografía (ECoG).

Originalmente, estos dispositivos se concibieron simplemente como un medio de comunicación y control ambiental para individuos con discapacidades [68]. Sin embargo, en los últimos años se han propuesto cada vez más aplicaciones derivadas de las interfaces cerebro-máquina tanto para individuos sanos, como para aquellos que presentan alguna discapacidad. Los avances tecnológicos han permitido aprovechar las BCI con fines re-creativos en aplicaciones de juegos y realidad virtual, donde brindan una modalidad de interacción con la experiencia de una manera alternativa, mediante la cual se puede controlar una simulación [42]. Las BCI también se han utilizado para permitir la expresión creativa de los sujetos, al traducir la actividad cognitiva en música y arte visual [50] o para rastrear cambios en estados cognitivos. Un ejemplo de estas investigaciones son las llevadas a cabo por Zander y Kothe [77] para detectar el estado de alerta de un sujeto. Otros ejemplos de usos actuales son la rehabilitación del control motor tras un accidente o el tratar estados alterados de la conciencia.

La mayoría de las BCI actuales utilizan la EEG como herramienta para inferir el estado mental y la intención comunicativa de los sujetos. Este sistema proporciona una visión espacial a los investigadores, de baja resolución, acerca de la actividad eléctrica en la corteza craneal [55]. Esta resolución va normalmente asociada al coste del dispositivo y a su relativa simplicidad, comparado con otros sistemas de BCI, como son los sistemas invasivos.

La investigación sobre las BCI relacionadas con las emociones de los sujetos está prosperando y cada vez atrae más atención e inversión. Algunas grandes tecnológicas como *Facebook* o el empresario Elon Musk han realizado grandes inversiones. EL proyecto hardware de *Facebook* se mantiene en secreto y la inversión del empresario le llevó a cofundar *Neuralink*, que tiene como objetivo el desarrollo de BCI novedosas. En este trabajo, el

objetivo principal consiste en el reconocimiento de las emociones humanas por medio de dispositivos BCI basados en EEG mediante el uso de algoritmos de ML.

En la Sección 2, se cubrirán aspectos generales del caso de uso. Desde la introducción al funcionamiento de las BCI, con su respectivo ciclo de vida, hasta los factores biológicos que toman parte en la formación de las emociones humanas. En la Sección 3, el trabajo se centra en estudiar el estado del arte de la detección de emociones. En un primer bloque se tratarán los distintos escenarios de aplicación en los que la detección de emociones puede ser interesante, se tratarán otras tecnologías usadas históricamente para esta labor, para posteriormente introducir los sistemas BCI al caso de estudio. Se compararán distintas metodologías de trabajo seguidas por autores distinguiendo en dos bloques los trabajos que se realizan capturando datos en vivo y los que hacen uso de bases de datos para la obtención de sus datos. A continuación, la Sección 4 cubre la metodología de trabajo seguida para el cumplimiento del objetivo principal, comentado anteriormente.

La Sección 5 explica cuáles han sido los procesos seguidos en cada una de las etapas del ciclo de vida del proyecto, haciendo hincapié en las decisiones de diseño consideradas, como son los algoritmos de ML utilizados para la clasificación o las técnicas de procesamiento llevadas a cabo. A continuación, la Sección 6 explica las particularidades de cada prueba llevada a cabo. Cada una de ellas sigue una metodología de trabajo distinta, pero con hechos comunes, que serán comparados en la Sección 7. En esta sección se comparan por un lado los resultados de los experimentos llevados a cabo y por otro se evalúan con trabajos de la literatura, para ser conscientes de la aportación real del trabajo llevado a cabo. Concretamente, se puede observar que la mayoría de experimentos binarios superan ampliamente el 93 % de precisión en la detección de emociones, superando ampliamente a trabajos como Yan et al. [76], Chen et al. [21] y Thammasan et al. [70]. Por su parte, los resultados de los experimentos multiclase son iguales o mejores que los proporcionados por autores como Mazumder [46], Kumar et al. [39] y Dabas et al. [24], superando el 90 % de precisión en todos. Finalmente, en la Sección 8, se hace un repaso del trabajo realizado, destacando resultados, limitaciones y posibles contribuciones futuras al caso de uso.

2. Background

En la presente sección se realiza una revisión sobre los conceptos más importantes relacionados con las interfaces cerebro-máquina, así como los principales usos que se le han dado, los tipos de BCI que existen y las fases del ciclo de uso de una BCI. Seguidamente, se hará un repaso de las emociones humanas desde el punto de vista fisiológico.

2.1. Interfaces cerebro-máquina

Una BCI es un sistema bidireccional que permite tanto adquisición de datos neuronales, mediante la medición de las ondas cerebrales, como neuroestimulación. De esta forma, es posible detectar las intenciones o el estado de un sujeto y actuar en consecuencia [54]. A continuación, se describen varios usos de estos sistemas en la actualidad.

Los sistemas basados en BCI comprenden una amplia área de investigación en constante crecimiento y expansión. Si bien inicialmente la investigación en BCI se centró en aplicaciones médicas para la monitorización y rehabilitación de pacientes [17], actualmente se proponen e investigan cada vez más aplicaciones alternativas en humanos sanos. Concretamente, un área donde está teniendo un gran auge corresponde con el seguimiento de los estados mentales y la decodificación de estos para obtener información sobre el sujeto [29]. Otro de los campos no relacionados con la medicina para el cual resulta útil el desarrollo de BCI es el campo de los videojuegos. Existen incluso revisiones del estado del arte, como la realizada por [30], que tienen como objetivo adaptar y controlar un videojuego utilizando señales cerebrales además de las habilidades físicas y mentales tradicionales del usuario. También existen otros trabajos relacionados con la robótica, como puede ser el control de una silla de ruedas o brazos robóticos, como se muestra en la Figura 1 [69].

Independientemente del uso que se les de, las BCIs se pueden clasificar en distintos tipos en función del grado de invasividad del sistema en el sujeto. Los sistemas no invasivos son actualmente los mas usados debido a que ofrecen la ventaja de no requerir cirugía, lo que puede suponer un riesgo elevado para la integridad de la persona. Estos sistemas funcionan mediante la adquisición de señales o estimulación, situando la interfaz sobre el cuero cabelludo. Sin embargo, esto puede presentar ciertas desventajas. La principal de ellas es el ruido y las interferencias no deseadas que capta el sistema, haciendo más costosos los procesos de tratamiento de las señales [16]. Algunos de los sistemas más usados actualmente se basan en técnicas de EEG (Figura 2a), o Magnetoencefalografía (MEG) (Figura 2b), aunque el uso de EEG está mucho más extendido porque, aun con la gran resolución espacio-temporal que presentan las señales captadas con MEG [47], el principal inconveniente que se presenta en este método de adquisición es que se requieren sensores sensibles y salas blindadas magnéticamente.

Los sistemas semi-invasivos utilizan ECoG. En muchos aspectos son similares a los sis-



Figura 1: Silla de ruedas controlada por un sistema de bci [8].

temas basados en EEG, ya que ambos utilizan registros biofísicos similares y los mismos mecanismos neurofisiológicos. Esto conduce a un enfoque común desde el punto de vista de procesamiento de la señal. Como principal diferencia, se destaca que estos sistemas semi-invasivos proporcionan una mejor resolución espacio-temporal que los métodos no invasivos, al recibir una cantidad de ruido menor, pero requieren de un procedimiento invasivo llamado craneotomía [58]. Este proceso consiste en colocar la interfaz dentro del cráneo, pero fuera del córtex cerebral.

Los sistemas invasivos son mayormente utilizados en el ámbito médico, como son los sistemas de Deep Brain Stimulation (DBS) para el tratamiento del Parkinson [31]. Existen también sistemas que tratan de precisar más con la activación individual de las neuronas, además de como sistema fisiológico global [52]. Estos últimos sistemas han sido probados principalmente en animales, y utilizan pequeños electrodos que se implantan en la corteza cerebral. Los sistemas invasivos tienen como principal ventaja una mayor resolución de información espacio-temporal precisa y una relación señal-ruido muy alta, lo que da como resultado un rendimiento del sistema significativamente mejorado. El principal inconveniente a tener en cuenta consiste en el deterioro de los electrodos. Al tratarse de dispositivos eléctricos en constante funcionamiento, el deterioro con el paso del tiempo es inevitable, por lo que muy posiblemente sea necesario remplazarlos por otros nuevos, lo que supondría una nueva cirugía [20].



(a) Ejemplo de BCI basada en EEG. [3]



(b) Ejemplo de BCI basada en MEG. [6]

Figura 2: Ejemplos de sistemas BCI no invasivos.

2.2. Fases del ciclo de vida de una interfaz cerebro-máquina

Independientemente del escenario de aplicación en el que se use la BCI, es necesario llevar a cabo una serie de etapas, ya definidas, que faciliten el cumplimiento de los objetivos propuestos. De acuerdo con el tratamiento de las señales adquiridas, encontramos dos fases, el procesamiento y la clasificación. Estas dos etapas se subdividen en otras subetapas que serán detalladas a continuación [43].

2.2.1. Procesamiento

En una etapa inicial, se debe realizar un proceso de adquisición de la señal, teniendo como objetivo la captura y el almacenamiento de esta para su uso en etapas posteriores. Una vez que se ha almacenado la señal, se debe llevar a cabo un preprocesamiento de la misma, tratando de realizar una limpieza y mejora en la señal con el fin de eliminar posibles ruidos o interferencias. En algunos de los sistemas más comunes, como EEG, estas señales son débiles y fácilmente alterables con ruido de otras fuentes. Particularmente, el propio cuerpo humano realiza tareas que producen impulsos eléctricos, como el parpadeo o movimientos oculares cuando se cambia el foco de visión, espasmos musculares o, incluso, latidos del corazón que pueden alterar estos datos [35]. En este sentido, se ha observado que la mejor forma de preprocesar esta información capturada consiste en el filtrado de los datos y no en su eliminación. A continuación, se mencionan algunos de los algoritmos que se usan para EEG, los cuales serán usados para cumplir los objetivos de este trabajo.

El filtro paso banda consiste en preprocesar la señal adquirida con el fin de seleccionar subconjuntos de frecuencias que resulten de interés para la clasificación de los datos. En la literatura se han documentado varias frecuencias de corte para el filtrado de paso de banda. Estas bandas de frecuencia se denominan delta, theta, alfa, beta y gamma, de

menor a mayor frecuencia, respectivamente.

Por su parte, el filtro notch está diseñado para excluir frecuencias específicas que puedan estar contaminando los datos, como pueden ser las originadas por redes eléctricas. Típicamente varía de 50 a 60 Hz dependiendo de la frecuencia de la señal eléctrica en el país específico [10]. En concreto, en Europa son 50 Hz.

El filtro Principal Component Analysis (PCA) se basa en la búsqueda de patrones similares en los datos utilizando una transformación lineal para convertir un conjunto de observaciones posiblemente correlacionadas en un conjunto de variables no correlacionadas, que se denominan componentes principales [63].

Finalmente, Independent Component Analysis (ICA) tiene como objetivo separar los artefactos de las señales obtenidas por medio del EEG en componentes que sean independientes basados en las características particulares de los datos sin depender de los canales por los que hayan sido recogidos. Ha resultado ser muy útil para la extracción de datos relacionados con los artefactos oculares [61].

2.2.2. Clasificación

Una vez que se ha eliminado el ruido e interferencias de las señales recibidas, la BCI necesita extraer características representativas de los datos mediante los cuales se realizará la clasificación, con el fin de identificar eventos de interés en las señales. En esta fase, se utilizan algoritmos de extracción de características para reflejar similitudes entre las señales capturadas de cada uno de los canales y una determinada clase, así como diferencias identificativas respecto al resto de clases [32]. En esta fase, se pueden reutilizar los algoritmos PCA e ICA mencionados anteriormente con el fin de reducir las muestras u otros que tratan los datos en función a la relación tiempo-frecuencia como son Autoregressive (AR) [32], Fast Fourier Transform (FFT) [60], o alguna de sus variantes como STFT [64] o Discrete Fourier Transform (DFT) [38].

Tras la etapa de extracción de características, se lleva a cabo el proceso de selección, el cual consiste en seleccionar las características que más aporten en la etapa de clasificación. Estas son concatenadas en un vector, que será el que se utilice para la fase de clasificación [12].

Seguidamente, se aplican distintos algoritmos encargados de, en una primera instancia, aprender de las distintas características seleccionadas para posteriormente poder decidir y clasificar en función de una determinada entrada. Es por esto por lo que es fundamental que los procesos de extracción y selección de características sean efectivos [54].

Para cumplir los objetivos de esta fase se utilizan tanto algoritmos de clasificación como de regresión, pudiendo estar basados en ML o Deep Learning (DL). Los clasificadores utilizan las características extraídas como variables independientes para definir límites entre los

diferentes objetivos en el espacio de características. Por el contrario, los regresores emplean las características seleccionadas de las señales EEG como variables independientes para identificar los eventos que interesen en la investigación.

A continuación, se exponen algunos de los algoritmos de clasificación que se van a usar en los experimentos del presente documento. En primer lugar, se presentan los algoritmos basados en ML, como son SVM, kNN y Random Forest. Seguidamente, se tratarán las redes neuronales como algoritmos de DL.

SVM es una herramienta de aprendizaje automático muy potente y versátil. Este algoritmo de clasificación es capaz de realizar clasificación lineal o no lineal, regresión e, incluso, detección de valores atípicos, lo que lo hace uno de los algoritmos más populares en machine learning. Las SVM han resultado ser especialmente efectivas para la clasificación de conjuntos de datos complejos pero de tamaño pequeño o mediano [54].

Por su parte, kNN trata de formar grupos separados en el espacio de características. La ventaja de tener en cuenta k vecinos en la clasificación es que la probabilidad de error en la decisión se reduce. Algunas muestras de entrenamiento pueden verse afectadas por ruidos, que pueden deteriorar los resultados. De este modo, si se toma una decisión que involucra a varios vecinos, resulta menos probable que ocurra un error [59]. Estos k vecinos se definen en una función ponderada que tiene en cuenta las similitudes entre las características de los mismos [25].

Los algoritmos de Random Forest son unos de los más potentes dentro de los árboles de decisión (*Decision Trees*). Estos son algoritmos muy versátiles de aprendizaje automático que pueden realizar tanto tareas de clasificación como de regresión, ofreciendo salidas simples o multiclas [26]. Los algoritmos de árboles de decisión y, en concreto, los de Random Forest, han demostrado ser algoritmos muy potentes, capaces de adaptarse a conjuntos de datos complejos.

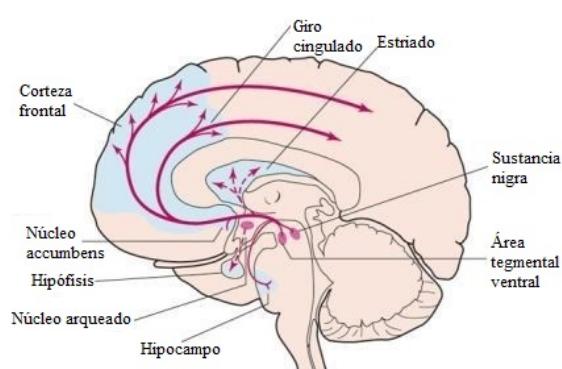
En cuanto a los algoritmos de DL, se tratan las redes neuronales, las cuales son algoritmos discriminantes que reconocen relaciones subyacentes en un conjunto de datos [44]. Estas redes se inspiran en el funcionamiento biológico del cerebro humano por el hecho de que este órgano, tanto en humanos como en animales, puede reaccionar de forma adaptativa a los cambios en los entornos internos y externos [79]. Por lo tanto, estas intentan imitar la actividad cerebral para resolver problemas. Su uso está ampliamente extendido para problemas de reconocimiento de patrones, debido a su capacidad posterior al entrenamiento para reconocer conjuntos de patrones relacionados con los datos del entrenamiento. En sistemas BCI suelen tener una precisión bastante alta, aunque trabajar con ellas suele ser complejo y requiere un volumen de datos muy elevado. Esto hecho es común, generalmente, en los algoritmos de DL.

2.3. Factores biológicos de las emociones humanas.

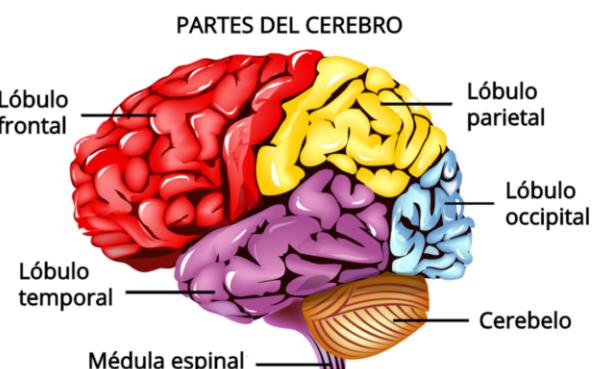
Las emociones, desde una perspectiva biológica, se definen como un cambio en el sujeto que involucra una serie de alteraciones de los distintos sistemas del ser humano. Estas se originan en Sistema Nervioso Autónomo (SNA) y pueden involucrar otros sistemas como el muscular, óseo y endocrino, movilizando al organismo para que se comporte de formas particulares [73]. Estas alteraciones son respuestas que se inician en el sistema límbico (Figura 3a) y son almacenadas en estructuras neuronales, que son las responsables de la memoria y el aprendizaje.

Específicamente, las emociones se forman en el hipocampo y el cerebelo, para posteriormente ser interpretadas y proyectadas en otras regiones del cerebro Figura 6, como son la corteza prefrontal, parietal y temporal [4]. La amígdala cerebral es una de las estructuras más importantes del sistema límbico, encargada de iniciar un proceso emotivo. Cuando esto ocurre, se activan otras áreas cerebrales, como son Área Tegmental Ventral (ATV) y el núcleo accumbens, relacionadas con la liberación de la dopamina. Esta es considerada el neurotransmisor más importante para generar una emoción. La liberación de esta sustancia puede ser sostenida o abrupta, lo que traerá consigo distintas respuestas del sujeto. Si la liberación de dopamina sucede de forma repentina, se producirán emociones negativas (furia o ira). Por el contrario, si la liberación es gradual, las emociones generadas serán positivas (felicidad).

Como se puede observar, realmente todas las emociones tienen factores comunes, como son las áreas cerebrales que las producen y el componente neuroquímico que las genera. Estas emociones son etiquetadas por medio de la activación de neuronas en el giro cingulado y, posteriormente, proyectadas a regiones superiores, como es el hipotálamo y, en una fase final, los lóbulos [4].



(a) Sistema límbico [9]



(b) Lóbulos del cerebro. [5]

Figura 3: Partes del cerebro humano.

Inicialmente, las emociones se estudiaron desde un punto de vista filosófico y antropológico [72]. No fue hasta mediados del siglo XX, con el estallido de las guerras mundiales, cuando la teoría y la investigación sobre las emociones humanas se aceleraron en el ámbito de la sociología, hasta tal punto que ahora representan uno de los puntos principales de investigación de las emociones humanas [14]. En la actualidad existen muchas teorías, respaldadas por hallazgos en investigaciones, que buscan explicar la dinámica emocional, donde algunos autores como Turner et al. [73] han tratado de integrar las teorías existentes y los hallazgos de la investigación en un análisis más global que sea capaz de comprender las emociones humanas. Gracias al desarrollo tecnológico en la obtención de representaciones visuales, como las tomografías [48], es posible conocer el circuito neuronal y fisiológico de las emociones.

Existen distintas metodologías para la clasificación de las emociones humanas. Según el psicólogo David G. Meyers, las emociones están compuestas por arousal fisiológico, comportamiento expresivo y experiencia consciente [53]. Estas teorías aparecen cada vez más como tema de discusión para conseguir estructurar el saber psiquiátrico. Históricamente, el enfoque categórico ha sido el más utilizado, desde publicaciones como [66] y [28] en las cuales se presentaban manuales de conducta humana.

Por otra parte, el enfoque dimensional ha ido obteniendo importancia de manera complementaria de la mano de modelos espectrales como [45] y [22]. Esto se debe a que el modelo categórico supone que el sujeto elija únicamente una emoción, cuando realmente puede suceder que se encuentre en múltiples a la vez, o no sepa asociar su estado actual a una única de las etiquetas. En concreto, uno de los modelos dimensionales más utilizados actualmente se trata de Self-Assessment Manikin (SAM). Como se muestra en Figura 4, este es un modelo basado en imágenes para medir una respuesta emocional de un sujeto [19]. Específicamente, existen escalas de un solo ítem que miden la valencia o placer de la respuesta (de positivo a negativo), la excitación percibida (de niveles altos a bajos) y las percepciones de dominio o control (de niveles bajos a altos).

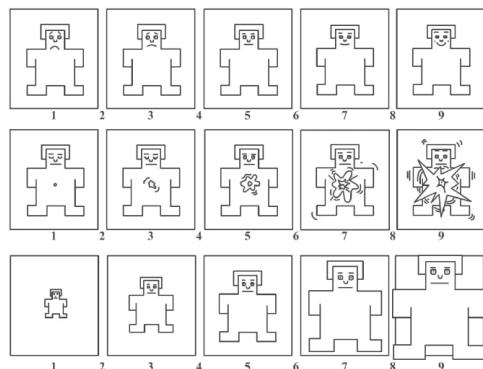


Figura 4: Esquema SAM [65]

3. Estado del arte

En la presente sección, se revisarán los métodos de reconocimiento de emociones más utilizados. También se hará mención a trabajos reseñables en este ámbito, destacando la metodología empleada y la precisión de los resultados. Por último, se investigarán las distintas bases de datos usadas por estos trabajos.

3.1. Escenarios de aplicación para la detección de emociones.

Gracias al avance tecnológico, se han podido diseñar distintos modelos capaces de reconocer las emociones humanas. Este reconocimiento ha seguido distintos procesos. En la investigación realizada por Elfenbein y Amdaby [27], se llevaron a cabo experimentos para el reconocimiento de emociones por medio de visualización y escucha de conversaciones de sujetos. El trabajo concluye que la precisión de las pruebas simplemente observando el rostro ofrecen un 81.2 % de precisión para las situaciones en las que el estado de ánimo es positivo, frente a un 76 % en las cuales el estado de ánimo era negativo. Por el contrario, cuando la evaluación depende de la escucha de las voces, se observa un 73.3 % de acierto para el estado positivo, frente a un 74.2 % del estado negativo.

Otros trabajos, tratan de reconocer el estado del sujeto por medio de expresiones faciales. En [49] se intentó reconocer estas emociones por medio de una serie de vídeos extraídos de la base de datos Interactive Emotional Dyadic Motion Capture (IEMOCAP). Esta contiene una serie de gestos realizados por actores y etiquetados por tres evaluadores. El clasificador gaussiano utilizado trataba de decidir a qué clase, entre *enfadado*, *feliz*, *neutral* y *triste* pertenece cada expresión examinando distintas zonas del rostro, como son la frente, las cejas, las mejillas y la barbilla. Este clasificador proporciona distintas precisiones para cada una de las zonas del rostro por separado. Como métricas globales, se obtuvieron las precisiones de 69.68 % para *enfadado*, 71.97 % para *feliz*, 54.64 % para *neutral* y 65.34 % para *triste*. En cuanto a las zonas faciales más descriptivas para la clasificación de las emociones, la barbilla es la zona que más precisión ofrece para los estados *enfadado* y *feliz*, con un 69.35 % y 75.8 % respectivamente. Para la etiqueta *neutral*, la zona que más precisión ofrece es la mejilla izquierda, con un 56.62 % y, para el estado *triste*, la mejilla derecha con un 69.63 %.

En [75] se hace referencia a otros métodos para el reconocimiento de emociones en niños. En concreto, el grupo de investigadores de este artículo utilizan la Emotional Competencies Scale for Young Children (ECSYC), un test que se ha validado para el reconocimiento de emociones en niños con edades de cuatro a cinco años. El estudio comprende cinco niveles, subdividiéndose cada uno de los mismos en diez estados emocionales. Estos estados son clasificados por profesores con la observación a largo plazo de los sujetos. Este experimento se llevó a cabo con 40 niños por medio de videojuegos que inducían emociones. El resultado determina que el mejor medio de reconocimiento consiste en tener en cuenta

tantos las expresiones faciales como la voz de los sujetos, obteniendo un 78.73 % de precisión, ya que teniendo en cuenta sólo la voz se obtiene un 60.85 % de precisión y un 46.7 % si sólo se tienen en cuenta las expresiones faciales.

Otro ejemplo de reconocimiento de las emociones derivado de las expresiones faciales es el llevado a cabo por Barhreini et al. [13], en el cual se obtuvo una precisión de un 83.2 %, siendo las detectadas con mayor precisión las positivas como *felicidad* y *sorpresa*, con precisiones de 94.9 % y 95.2 %, respectivamente.

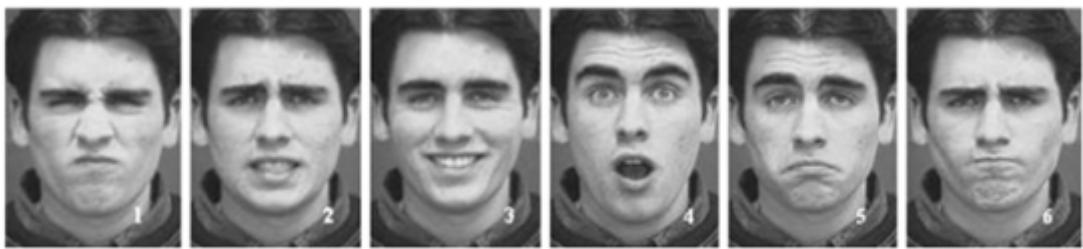


Figura 5: Ejemplo de expresiones faciales mostradas para el reconocimiento de emociones [7].

Otros trabajos han tratado de realizar este tipo de reconocimientos, pero teniendo en cuenta el mayor número de características que se pudieran obtener del sujeto, derivadas de su postura corporal. En [37] se obtuvo un 70 % de acierto en el reconocimiento de las emociones *enfado*, *confusión*, *miedo*, *felicidad*, *interés*, *relajación*, *tristeza*, *asombro* y *sorpresa*. En [36] se llevaron a cabo dos estudios. Por un lado, se intentan fijar los límites que tenían hasta la fecha los sistemas de reconocimiento de emociones por medio de expresiones corporales. Principalmente se buscaba un reconocimiento automático de las emociones por medio de las dimensiones *valencia*, *excitación*, *control de la situación* y *evasión de la emoción*. Esta resolución mostró errores relativos en *valencia*, *excitación*, *control de la situación* y *capacidad de evitar mostrar una emoción* de 21 %, 21 %, 19 % y 19 %, respectivamente. Por otro lado, se intentó llevar a cabo un reconocimiento automático de emociones con análisis discriminante de mezcla no lineal, obteniendo mejoras frente a los sistemas de reconocimiento del primer experimento, con valores de 12 % para *valencia*, 10 % para *excitación* y *control de la situación*, y 11 % para *evasión*.

3.2. Incorporación de sistemas BCI para el reconocimiento de emociones

La incorporación de las BCIs trajo consigo un abanico mucho más amplio y preciso en el reconocimiento de emociones. En los inicios, los trabajos eran realizados con bases de datos propias con pocos individuos, cinco en el caso de [18] y seis en [51]. En ambos casos se usan vídeos como modo de generar las emociones en los sujetos, que actúan en el

experimento durante un tiempo determinado: diez minutos en el primer artículo y en el segundo se utilizan dos vídeos al azar de entre cinco y 24 segundos. Otros hechos relevantes para este proceso son la calidad del hardware, el número de electrodos o la posición en la que se coloquen en el sujeto. En cuanto a la metodología seguida por los autores, Bos et al. [18] realiza un filtrado paso-banda para el preprocesamiento y se lleva a cabo una extracción de características usando FFT para poder realizar una separación en bandas de frecuencia. Esto también sirve para la selección de características, ya que el autor cita que en la literatura se seleccionan las bandas alfa y beta, por lo que hace lo propio en su investigación. En cuanto a la clasificación, se usan algoritmos lineales como son Naive Bayes y el análisis discriminante de Fisher. Los resultados más precisos se obtuvieron con el electrodo Fpz en las bandas alfa y beta, con un 82.1 % de acierto.

Para la investigación de Murugappan et al. [51] se utiliza el método Average Mean Reference (AMR) para el preprocesamiento, seguido de WT para la extracción de características. Finalmente, se usaron dos algoritmos no muy comunes en la literatura como son Fuzzy-C y Fuzzy-K. Aun así, algunos trabajos siguen llevando a cabo experimentos con sujetos seleccionados y aumentando su base de datos propia. Recientemente, César Cavalcanti Roza y Adrián Postolache [23] llevaron a cabo un experimento con ocho sujetos y 13 simuladores para captar las emociones de conductores de aerolíneas en distintos contextos. El objetivo era clasificar las emociones como *feliz*, *triste*, *enfadado*, *sorprendido* y *temeroso* usando redes neuronales. La precisión de este artículo fue del 53.18 %, realizando extracción de características por medio de WT y la clasificación con SVM. Algunos autores, como Mazumder [46], han seguido metodologías parecidas para sus experimentos. En este caso, el autor también extrae características con WT, pero además también utiliza STFT, Hjorth y AR. Esto proporciona un mayor número de características para realizar la clasificación, la cual se llevó a cabo también con SVM. En este caso, se alcanzó un 90.41 % de precisión en la detección de las emociones *feliz*, *triste*, *temeroso* y *relajado*.

3.3. Bases de datos

En la actualidad, los estudios más recientes usan bases de datos para evitar que los investigadores tengan que realizar el proceso de adquisición de la señal [71]. En concreto, los datos extraídos de la cita muestran datos de uso de distintas bases de datos. La más usada, con un 49 % de uso, es la DEAP, un 23 % para SEED y, finalmente, otro 23 % para las investigaciones que seleccionan sujetos para la adquisición de sus datos. El porcentaje restante es completado, acorde con esta revisión, por otras bases de datos menos utilizadas como HCI y RCLS. Sin embargo, los datos fluctúan con los recogidos por [67], en el que se indica que lo más usado, con un 43,75 % son las bases de datos propias de las investigaciones, seguidas por la DEAP, con un 18,75 %, en tercer lugar otras como SEED, AVRS, e IAPS con un 6,25 % y, finalmente, IADS, DREAMER, MediaEval, Quran Verse, DECAF y NAPS con un 3,13 % cada una.

La colección de datos SEED [1] es un conjunto de señales de EEG recogidas de 15 sujetos visualizando 15 extractos de películas en los cuales se etiquetan las emociones como *positivas*, *negativas* o *neutrales*. Esta colección tiene una extensión, SEED-IV, que amplía las etiquetas a *feliz*, *triste*, *temeroso* y *neutral*, añadiendo un rastreador de la vista, como es el sistema *eye-tracking*. Autores como Pane et al. [57] y Zhang et al. [78] han hecho uso de la base de datos SEED para clasificar las emociones de los sujetos entre *positivo*, *negativo* y *neutral*, siguiendo enfoques parecidos al realizar extracción de características con FFT. Las diferencias comienzan con la selección de las mismas. Mientras que el primero realiza selección por medio de SDA, el segundo no lleva a cabo selección de características. La diferencia principal comprende los algoritmos de clasificación utilizados y por tanto la precisión de sus resultados. El primer autor utiliza LDA y obtiene una precisión de 93.21 % en su clasificación, mientras que el segundo obtiene 82.16 % con redes neuronales.

La base de datos más usada en la literatura es la DEAP [2]. Esta es un conjunto de datos de código abierto usado para analizar estados afectivos humanos. Los datos adquiridos pertenecen a 32 participantes, los cuales visualizan 40 videoclips musicales con un cierto nivel de estímulos evaluados en 4 clases: *arousal*, *valence*, *dominance* y *liking*. Estas clases son evaluadas de 1-9 y su valor es el que se usa para etiquetar las emociones, de acuerdo al modelo SAM [19]. En cuanto a las características de las grabaciones, en este caso se usan 48 canales distribuidos de la siguiente forma. En primer lugar, 32 canales EEG. Adicionalmente, 12 canales periféricos, tales como canales de control de la respiración, temperatura y rastreadores oculares. Posteriormente, tres canales no usados, así como y un canal de estado que contiene marcas que podrían ser de interés para los datos, como pueden ser el inicio y el fin del experimento, el incio de la grabación o el inicio de la reproducción del vídeo. La frecuencia de muestreo en este caso es de 512 Hz. Pero, además de los datos en crudo, este dataset proporciona los datos preprocesados. En este caso, se produce una reducción del muestreo a 128 Hz y se aplica un filtro paso banda entre 4-45 Hz.

Algunos autores han utilizado estos datos con metodologías similares para llevar a prueba sus investigaciones, como Özerdem y Polat [56], Yan et al. [76] y Thammasan et al. [70], realizando a cabo la extracción de características con WT o DWT. De estos trabajos mencionados, sólo en el primero se llevó a cabo selección de características, por medio de la selección de canales. En este caso, los tres trabajos tratan de clasificar dos estado. En el primer trabajo, *positivo* y *negativo*, mientras que en los dos últimos la clasificación de *valencia* y *excitación*. Tanto en el primero como en el último se usó kNN como método de clasificación, obteniendo un 72.92 % en [56] y 84.05 % y 86.75 % para ambas emociones en [70], respectivamente.

C. Shahnaz et al. [62] usaba SVM para llevar a cabo clasificaciones binarias de cada una de las etiquetas que ofrece la DEAP. Para las fases de extracción y selección de características usó DWT y PCA respectivamente. Los resultados que obtuvo fueron de entre 60-70 por

ciento de precisión en todas las etiquetas. Por su parte, Dabas et al. [24] realiza una clasificación 3D, es decir, usa las etiquetas de “valencia”, “excitación” y “gusto” de la DEAP en clasificaciones alto-bajo de cada una de las etiquetas, para construir un espacio de emociones más grande. En cuanto a su metodología de trabajo, usan directamente clasificadores sobre los datos preprocesados de la DEAP. Uno de ellos es SVM, para el que obtiene un 58.9 % de precisión. El otro, Naive Bayes, proporciona más precisión, 78.06 %.

Ullah et al., [74], realiza distintos experimentos siguiendo distintas metodologías. Como método general, se extraen características usando datos estadísticos de las señales, características del dominio y características del espectrograma y, posteriormente, la selección de características se realiza mediante PCA. En un principio, se realizan evaluaciones individuales de los canales y después se realiza una evaluación conjunta de los 40 canales usando SVM, obteniendo un 62.3 % para valencia y un 56.2 % para excitación. Para los mismos datos, los autores también hacen uso del algoritmo kNN, para el que obtienen la precisión de 60.4 % para valencia. Finalmente, los autores construyen un algoritmo Sparse Discriminative Ensamble Learning (SDEL) que finaliza obteniendo un 82.2 % de acierto, el cual es el modelo que mejor les funciona. Por su parte, Asghar et al. [11] realizan una clasificación usando SVM y kNN para realizar evaluaciones 2D con las etiquetas “valencia” y “excitación”. En este caso, se han realizado búsqueda de hiperparámetros con distintos kernels y número de vecinos. En caso del algoritmo SVM, el mejor kernel ha resultado ser cúbico y el número de vecinos óptimo para kNN 10, obteniendo un 77.4 % y 73.6 % de acierto respectivamente.

Al igual que se presentaba en trabajos con bases de datos propias o que usaban SEED, en el caso de las investigaciones que usan la DEAP también es frecuente encontrar metodologías de trabajo en las cuales se usan las transformadas de Fourier para llevar a cabo la extracción de características. Lv et al. [41] y Chen et al. [21] realizan una extracción de características similar de los datos, pero no siguen la misma metodología para clasificar. Por un lado, la primera cita usa tanto SVM como LDA para clasificar en función de la valencia y la emoción del sujeto, obteniendo resultados bastante mejores para el algoritmo lineal de SVM (74.6 %), frente a LDA (51.5 %). Por otro lado, el segundo artículo obtiene una clasificación mucho mejor de las emociones *felicidad* y *tristeza*, llevando a cabo selección de características por medio de GA y usando el clasificador AdaBoost.

En la tabla Tabla 1 se lleva a cabo una comparación de algunos trabajos recientes estudiados en la literatura, así como la presentación de sus metodologías y resultados. De este modo, se podrá obtener una visión más general sobre las técnicas de procesamiento más utilizadas, las cuales pueden ser usadas de guía para realizar posteriormente la implementación de los experimentos. Como apunte extra, para la comprensión de los ciclos de vida, en los trabajos que no han llevado a cabo selección de características para el procesamiento, se ha dejado en blanco la casilla correspondiente.

REFERENCIA	BASE DE DATOS	EXTRACCION DE CARACTERÍSTICAS	SELECCIÓN DE CARACTERÍSTICAS	CLASIFICACIÓN	EMOCIONES	PRECISIÓN
[2019] Asghar et al. [1]	SEED DEAP	AlexNet	Bag of Deep Features	SVM kNN	Baja/Alta valencia Baja/Alta excitación	DEAP: SVM 77.4% kNN 73.6% SEED: SVM 93.8% kNN 91.4%
[2019] Ulah et al. [74]	DEAP	Datos estadísticos de las señales Características del dominio WT Características del espectrograma	PCA	SVM individualmente kNN individualmente Modelo conjunto	Negativo	SVM: Valencia:62.3%, Excitación:56.1% kNN: Valencia:60.4%, Excitación:55.4% Modelo conjunto: Valencia:74.53%, Excitación:82.81%
[2019] César Cavalanti Roza y Adrian Postolache [23]	Propia	Cálculo en dominio del tiempo WT		ANN	Feliz Triste Enfadado Sorprendido Temeroso	53.18 %
[2019] Mazumder [46]	Propia	STFT WT Hjorth AR		SVM	Feliz Triste Temeroso Relajado	90.41 %
[2019] Li et al. [40]	Propia RCLS SEED	Cálculo en dominio del tiempo WT		GRSLR	Feliz Triste Neutral	81.13 %
[2019] Zhang et al. [78]	SEED	FFT		CNN	Positivo Negativo Neutral	82.16 %
[2019] Yan et al. [76]	DEAP	WT		LSTM NN	Valencia	59.03 %
[2019] Chen et al. [21]	DEAP	Cálculo en dominio del tiempo FFT		SVM LDA	Excitación Valencia	74.6 %
[2018] Kaur et al. [34]	Propia	Higuchi		RBF SVM	Feliz Calmado Enfadado	51.5 %
[2018] Dabas et al. [24]	DEAP			Naive Bayes SVM	Baja/Alta valencia Bajo/Alto gusto	60 %
[2018] Pan et al. [57]	SEED	FFT	SDA	LDA	Positivo Negativo Neutral	78.06 % 58.90 %
[2017] Özerdem y Polat [56]	DEAP	DWT	Selección de canales	MLP kNN	Positivo Negativo	77.14 % 72.92 %
[2017] Lv et al. [41]	DEAP	Cálculo en dominio del tiempo FFT	GA	AdaBoost	Felicidad Tristeza	95.84 %
[2017] Thannassan et al. [70]	DEAP	DWT		kNN	Valencia	84.05 % 86.75 %
[2016] Bhatti et al. [15]	Propia	STFT WT		SVM MLP kNN	Feliz Triste Enfadado	75.02 % 78.11 % 72.81 %
[2016] Kumar et al. [39]	DEAP	Información relación frecuencia-fase	Eliminación de características	SVM	Baja/Alta valencia Baja/Alta excitación	64.84 % 61.17 %
[2016] C. Shahnaz et al. [62]	DEAP	DWT	PCA	SVM	Excitación Gusto Dominio	66.51 % 66.88 % 70.52 %
[2015] Lancoviello et al. [33]	Propia	WT	PCA	SVM	Negativo	90.2 %

Tabla 1: Comparativa de trabajos estudiados de la literatura.

4. Análisis de objetivos y metodología

4.1. Objetivos

En esta sección se detallan los objetivos que se pretende abordar en este TFG. Una vez detallado el ciclo de vida de una BCI, el objetivo principal del presente documento es desarrollar un sistema que capaz de predecir emociones por medio de EEG y clasificarlas haciendo uso de algoritmos de Machine Learning. Para cumplir este objetivo principal, se ha subdividido en una serie de subobjetivos:

- Estudio del estado del arte para el presente caso de estudio. Comienza con los conocimientos básicos de cómo funciona una BCI junto con EEG, las emociones desde el punto de vista fisiológico y, finalmente, la revisión de los trabajos en los que se exponen distintas metodologías para la clasificación de emociones humanas.
- Estudio de los posibles métodos de adquisición de datos. En este apartado se estudiarán cuáles son las fuentes de datos más usadas por los autores, desde una adquisición propia mediante BCIs, hasta la existencia de repositorios de datos públicos.
- Procesamiento de los datos. Para cumplir este objetivo nos centramos en estudiar las distintas técnicas de procesamientos que pueden ser aplicadas sobre los datos capturados por la interfaz, analizando cuáles son las más usadas en la literatura.
- Entrenamiento de modelos mediante ML. Una vez que se ha realizado el procesamiento, se plantea la realización de una fase de extracción de características para, posteriormente, hacer una selección de las más descriptivas. Por último, se aplican distintos algoritmos de clasificación basados en ML para estudiar su precisión en la predicción de emociones.
- Análisis de los resultados y comparación con el estado del arte. Este último subobjetivo pretende proporcionar una visión general sobre los experimentos llevados a cabo. En este paso compararemos los distintos modelos de entrenamiento llevados a cabo, así como la comparación de los mismos con resultados obtenidos en la literatura.

4.2. Metodología

En esta sección se describen los distintos pasos que se han llevado a cabo para el desarrollo de los experimentos y, en consecuencia, el cumplimiento de los objetivos marcados anteriormente. Este proyecto comienza con un análisis de la literatura y finaliza con la realización de los experimentos y comparación con lo ya estudiado en la literatura.

La estructura del proyecto viene determinada por 1) estudiar el estado del arte del reconocimiento de emociones por medio de una BCI basada en EEG, 2) estudiar las bases de datos disponibles de las cuales obtener los datos para los experimentos, 3) procesar

los datos raw obtenidos, 4) realizar entrenamientos de los datos mediante algoritmos de ML y 5) analizar los resultados de los distintos modelos entrenados y, posteriormente, compararlos con los de la literatura.

4.2.1. Estudio del estado del arte del caso de uso

El primer paso ha consistido en conocer qué es una BCI, cómo funciona y cuáles son sus principales usos y escenarios de aplicación más comunes. Para el caso de estudio de las emociones humanas, ha sido necesario también entender cómo funcionan desde el punto de vista fisiológico y revisar qué métodos se han llevado a cabo a lo largo de la historia para reconocer las emociones. Posteriormente, se ha pasado a estudiar como se ha aplicado la integración de las interfaces cerebro-máquina para reconocimiento de emociones. Finalmente, abordamos las distintas técnicas de preprocesamiento y ML necesarias para llevar a cabo las clasificaciones.

4.2.2. Estudio de los datasets existentes

Una vez conocemos el funcionamiento de las BCIs y su relación con el reconocimiento de emociones, es necesario conocer de dónde proceden los datos más usados por los trabajos ya realizados. Este paso nos proporciona un *feedback* acerca de qué nos interesa más como investigadores: si realizar pruebas construyendo bases de datos privadas o utilizar las públicas, citadas en la literatura, lo cual es lo más común en este caso de uso.

Debido a las dificultades derivadas de la Covid-19 para realizar este tipo de experimentos a un número considerable de sujetos, la solución más factible que se ha encontrado para la realización del trabajo supone usar bases de datos públicas. De esta forma, es posible realizar una comparación con los trabajos realizados en la literatura que usen esta misma base de datos.

4.2.3. Procesamiento de los datos contenidos en el dataset seleccionado

El procesamiento de los datos consiste en implementar las dos primeras fases del ciclo de BCI. Este paso resulta necesario para la eliminación de ruidos y artefactos de los datos, que puedan dificultar la clasificación. En esta etapa se estudió cuáles son los más utilizados en la literatura para aplicarlos posteriormente a nuestro caso de uso.

4.2.4. Entrenamiento de los modelos mediante ML

Tras aplicar el procesamiento, es necesario aplicar las distintas etapas de ML para la detección de emociones. Este paso es fundamental para la completitud del objetivo general consiste en la clasificación de los datos en emociones etiquetadas mediante algoritmos de ML. El procedimiento a seguir comienza con la extracción de características de los datos

y la selección de las que sean más relevantes, siguiendo metodologías expuestas en la literatura para, finalmente, aplicar distintos algoritmos haciendo uso de distintas librerías de Python como, por ejemplo, *sklearn*.

En el presente trabajo se han llevado a cabo clasificaciones tanto binarias como multiclas. Por un lado, se ha tratado de distinguir, de entre dos estados de ánimo, cuál es más acorde a la emoción que siente el sujeto. Por otro, se ha tratado de realizar esta clasificación pero con un número de emociones mayor, que nos ha permitido determinar características propias de cada estado de ánimo en un sujeto.

4.2.5. Análisis de los resultados y comparación con el estado del arte

Una vez los datos han sido procesados y clasificados, se ha analizado que los resultados sean coherentes y se han comparado con las metodologías equivalentes seguidas por la literatura, con el fin de identificar ventajas y debilidades de nuestro procesamiento, que se puedan subsanar en futuros trabajos.

5. Diseño y resolución del trabajo realizado

En esta sección se presentarán las decisiones de diseño llevadas a cabo para cumplir el objetivo de reconocer y clasificar emociones por medio de una BCI mediante EEG haciendo uso de algoritmos de ML. Se han llevado a cabo una serie de experimentos que hacen uso de distintas metodologías para clasificar tanto emociones binarias como cuaternarias. Estos experimentos siguen el ciclo de vida de una BCI, como se muestra en la figura Figura 6. A lo largo de la sección se irá profundizando en cada una de las fases para explicar las decisiones tomadas sobre la misma.

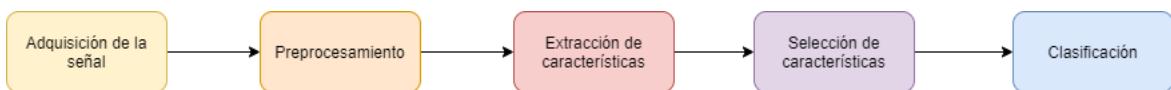


Figura 6: Fases del ciclo de vida de una BCI seguidas en este trabajo.

5.1. Adquisición de la señal

Como se mencionó en la sección anterior, hemos tomado la decisión de llevar a cabo la adquisición de la señal procedente de una base de datos pública, siendo la elegida DEAP [2]. Esto se debe a que cuando se llevó a cabo la revisión de la literatura, en los dos artículos que hacían referencia a las bases de datos más utilizadas por la literatura en los últimos años, ambos mencionaban que esta base de datos era la más frecuente, con un 49 % y 43.75 % de uso, respectivamente. Esta base de datos contiene dos tipos de información:

Por un lado, se hizo un experimento online a 14 sujetos, en el que ellos mismos se autoevaluaban. Los ficheros referentes a este experimento contienen el identificador del vídeo que visualiza el usuario, de entre una lista de 120 vídeos, que se asignan de forma aleatoria; una valoración de entre uno y nueve de los atributos valencia, emoción y dominio; un selector de la emoción que contiene 16 emociones; y, finalmente, un valor entero que indica el peso que tiene la emoción seleccionada sobre los atributos mencionados anteriormente para reconocer la emoción. Este valor está comprendido entre cero y cuatro, siendo el valor mínimo *débil* y el valor máximo *fuerte*.

El segundo experimento contiene datos más interesantes para nuestras pruebas, al presentarse los datos recogidos sobre los valores fisiológicos, adquiriéndose mediante una BCI, de 32 voluntarios que observaron 40 vídeos con música. El dataset proporciona un archivo que contiene todas las calificaciones de los vídeos de los participantes recopiladas durante el experimento. El archivo *participant_ratings* viene proporcionado *ods*, como *xls* y *csv*.

La tabla en el archivo contiene una fila por calificación de vídeo de participante y las columnas mostradas en Tabla 1. Las columnas de *Participant_id* y *Trial* contienen los identificadores de los sujetos y de los experimentos específicos. Estos experimentos se

Nombre de la columna	Contenido de la columna
Participant_id	Identificador único del sujeto (De 1 a 32)
Trial	Número de la prueba
Experiment_id	Identificador del vídeo
Start_time	Comienzo del experimento
Valence	Valor de la valencia (De 1 a 9)
Arousal	Valor de la emoción (De 1 a 9)
Dominance	Valor del dominio (De 1 a 9)
Liking	Valor del agrado (De 1 a 9)
Familiarity	Valor de la familiaridad (De 1 a 5)

Tabla 2: Columnas del fichero participant_ratings.csv y su descripción.

identifican por el valor de la columna *Experiment_id*. Los valores de la columna *start_time* fueron registrados por el software de presentación. Las columnas de valencia, la excitación, el dominio y el agrado se calificaron directamente después de cada prueba en una escala continua de nueve puntos, utilizando SAM para visualizar las calificaciones de valencia, excitación y dominancia. Para dar *me gusta* (es decir, ¿cuánto te gustó el vídeo?), se usaron los iconos de pulgar hacia arriba y hacia abajo. Finalmente, la columna familiaridad se calificó después del final del experimento en una escala de números enteros de cinco puntos (desde *nunca lo escuché antes* hasta *escucharlo con regularidad*):

El dataset también nos proporciona información sobre los vídeos y los participantes. Los vídeos son prestados en el fichero *video_list.xls*, en el cual se muestra el identificador del vídeo, el enlace a su visualización en la plataforma *Youtube*, la emoción que pretende transmitir y los datos medios de los valores de valencia, excitación, dominancia y gusto de cada uno de los vídeos, como media del adquirido de todos los sujetos. En el fichero donde se muestra la información de los sujetos, se muestra el identificador del sujeto en la prueba; la edad, la cual está en el rango de 19-37 años; y el género, siendo el número de hombres y mujeres prácticamente el mismo (17 por el género masculino y 15 por el femenino). También se indican otros datos como si son diestros o zurdos resultando que 31 de 32 sujetos son diestros; si tienen problemas de visión, su nivel de estudios; su nivel de consumo de ciertas sustancias como café, alcohol, tabaco; otras sustancias estupefacientes; horas de media de sueño; y perímetros craneales.

Una vez conocido esto, pasamos a describir el fichero que contiene los datos de las grabaciones del EEG. Estas grabaciones son proporcionadas tanto *raw* como preprocesados. Ambos casos proporcionan a los usuarios 32 ficheros. En el caso de los datos *raw*, los archivos tienen la extensión .bdf (formato de datos de BioSemi generado por el software de grabación Actiview), cada uno con 48 canales adquiridos a 512 Hz. (32 canales EEG, 12 canales periféricos, tres canales no utilizados y un canal de estado).

Los canales están distribuidos según el sistema 10/20 en el cuero cabelludo. En nuestro caso, al tratarse de reconocimiento de emociones por EEG, sólo haremos uso de los primeros 32 canales, por lo que descartaremos los siguientes 13, que no se corresponden con encefalograma, sino con canales periféricos que quedan al margen de nuestra investigación.

Los datos se registraron en dos lugares separados. Los participantes 1-22 se registraron en Twente y los participantes 23-32 en Ginebra. Debido a una corrección del hardware, existen algunas diferencias menores en formatos. Primero, el orden de los canales de EEG es diferente para las dos ubicaciones. En segundo lugar, la medida de Galvanic skin resistance (GSR) tiene un formato diferente para cada ubicación. Este valor hace referencia al valor de resistencia de la piel en los sujetos. Mientras que para los primeros sujetos la unidad de medida es *nano-Siemens*, en el segundo se proporciona en *ohmios*.

5.2. Preprocesamiento

En la base datos se proporcionan los ficheros con la fase de preprocesamiento ya realizada. Nuestra elección ha sido partir de estos datos para nuestros experimentos, ya que el procesamiento realizado se basa en el comúnmente llevado a cabo por la literatura: reducción de muestras y aplicar un filtro paso-banda (4-45 Hz).

Estos archivos contienen reducción del muestreo a 128Hz, preprocesando y segmentando los datos, tanto en Matlab (data_preprocessed_matlab.zip), como en los formatos de python / numpy en *Pickle* (data_preprocessed_python.zip). En el propio dataset se indica que esta es la versión de los datos más adecuada para probar distintas técnicas de clasificación o regresión sin la molestia de procesar primero todos los datos.

Cada fichero .dat de los participantes contiene dos arrays: uno con los datos de tamaño 40x40x8064 (vídeo, canal, bloque datos) y otro con las etiquetas de tamaño 40x4 (vídeo, cuatro etiquetas).

5.3. Extracción de características

Para la fase de extracción de características se ha usado una de las transformadas de Fourier, la STFT, con el fin de obtener información en base a las frecuencias de los datos en un momento determinado.

Para ello, hemos definido una serie de funciones que, en base a un determinado canal de un determinado vídeo y fijando ciertos parámetros, nos proporcionan información de valor sobre los datos. El parámetro fs se corresponde con la frecuencia de muestreo, la cual hemos indicado que se corresponde con 128, como se comentó en la fase previa. Finalmente, la ventana que deseamos es *hanning*, la cual presenta una forma cónica formada por el uso de un coseno ponderado. La información obtenida se corresponde con cinco arrays, uno para cada banda de frecuencia, que almacenarán los valores medios de los datos recogidos

por el usuario. De esta forma, repitiendo el proceso para cada canal de cada vídeo, se obtienen cinco estructuras de datos a partir de una única con la que partíamos.

Para todos los experimentos, menos para el primero, para el cual queríamos saber cuánto de representativos eran los datos por sí solos, hemos llevado a cabo esta extracción de características. Estos experimentos se presentan en la sección 6.

5.4. Selección de características

En cuanto a la selección de características, se han llevado a cabo distintas metodologías en función de los experimentos realizados: Selección de bandas de frecuencia, unión de bandas de frecuencia y selección de canales. Dado que las principales diferencias entre los experimentos residen en esta etapa del ciclo de vida, en la sección 6 se explicará concretamente cada una de las técnicas.

5.5. Clasificación

Para llevar a cabo la clasificación se han seguido dos esquemas. Inicialmente, el trabajo se centró en tomar la etiqueta de valencia para determinar el estado de ánimo del sujeto entre las emociones *happy* y *sad*. Esto lo hemos llevado a cabo atendiendo a la literatura, donde se indica que valores superiores a cinco, cuando la escala del modelo SAM va de uno a nueve, se corresponden con el estado *feliz* y valores menores se corresponden con *triste*. Los primeros cuatro experimentos se corresponden con este tipo de clasificación binaria, cuyos resultados compararemos más adelante.

Por otro lado, para la clasificación multiclase, hemos tenido en cuenta dos de las columnas proporcionadas en las etiquetas: valencia y excitación. En la literatura se cita la forma de determinar emociones en base a valores combinados de estas. Así, baja valencia y baja excitación, significan tristeza (etiquetado como *sadness*); baja valencia y alta excitación, enfado (*anger*); alta valencia y baja excitación, placer (*pleasure*); y alta valencia y alta excitación, felicidad (*joy*). Este valor de alto o bajo lo hemos tomado como mayor o menor de 4.5, que es el valor intermedio en el rango. La clasificación cuaternaria se lleva a cabo en los últimos tres experimentos.

En cuanto a los parámetros con los que se define el *test_split*, los mejores valores para el tamaño de los conjuntos de entrenamiento y test fue 80 % - 20 %, respectivamente. Para todos los experimentos se han llevado a cabo clasificaciones con tres de los algoritmos más comunes y eficaces de la literatura: Random Forest, SVM y kNN. Para todos ellos se usan distintas etapas para encontrar combinaciones eficientes y eficaces, que serán comparadas posteriormente. Esto consiste en una búsqueda de hiperparámetros para los tres algoritmos por medio de la función *GridSearchCV*. Estos hiperparámetros son: para Random Forest, *min_samples_split* y *max_depth*; para SVM, *C* y el kernel; y para kNN, el número de

vecinos con $n_neighbours$ y $weights$. De esta forma, para cada sujeto se creará un modelo individualmente con los parámetros que mejor se ajusten a la forma de sus datos.

6. Experimentos realizados

En esta sección se van a describir cada uno de los experimentos llevados a cabo, identificando los algoritmos y tomas de decisiones adoptadas para cada una de las etapas del ciclo de vida de una BCI.

En todos los experimentos se ha llevado a cabo un ajuste de hiperparámetros, a excepción del primero. Estos parámetros se muestran en tablas a lo largo de cada explicación mostrando cuáles son los valores óptimos a tomar para la construcción de los modelos más precisos posibles.

6.1. Experimento 1

El primer experimento es el más simple de todos, como se muestra en Figura 7, y consiste en la clasificación directa de los datos sin realizar extracción de características.

Tras haber obtenido datos de todos los experimentos y comparar, resultó que este era el menos eficiente en cuanto a tiempo y recursos y el que peores tasas de acierto producía. Esto va en la dirección de lo esperado, ya que se tratan de datos sin tratar para realizar las clasificaciones y estos resultan más grandes y menos descriptivos.

Es por esto, por lo que hemos considerado que realizar una búsqueda de hiperparámetros tampoco aportaba nada en nuestro trabajo, al existir alternativas mejores y debido también al elevado tiempo de ejecución. Además, no hemos adaptado este experimento para el reconocimiento de emociones cuaternario, ya que el resultado sería paupérrimo.

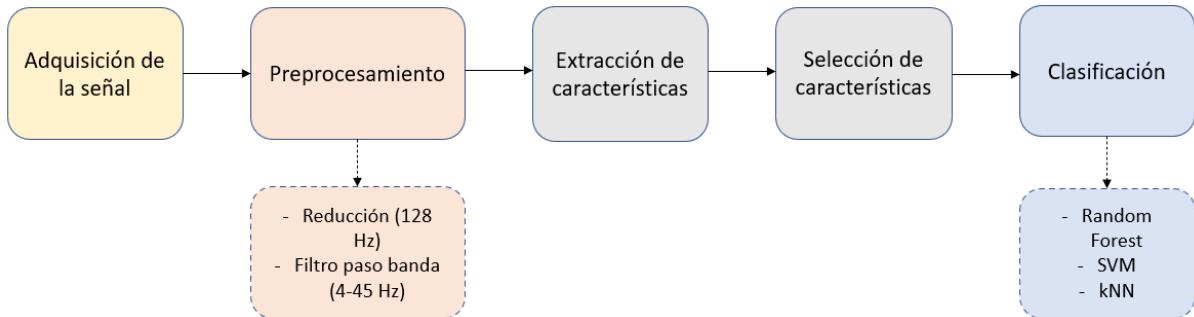


Figura 7: Metodología seguida para el experimento 1 binario.

6.2. Experimento 2

El ciclo de vida de la metodología para este segundo experimento se corresponde con el mostrado en la Figura 8. En este caso, sí que se realiza extracción de características, como se puede observar, por medio de STFT con el fin de posteriormente dividir los datos

en base a sus frecuencias. El procedimiento consiste en crear cinco estructuras de datos que contengan los datos de cada una de las bandas, lo que da lugar a unos dataframes de 64x40x32. Si se compara con el tamaño del fichero que se ofrecía en un principio (8064x40x40), el que vamos a utilizar para la clasificación es mucho menor. Cada bloque de datos ahora contiene 64 valores, que se corresponde con un array con las medias de los valores i-ésimos de los bloques de datos que contiene el bloque de datos inicial. Seguimos teniendo los 40 vídeos, ya que desprendernos de algunos de ellos sería perder información y reducimos a 32 canales, que como se explicó anteriormente, son los relativos a EEG.

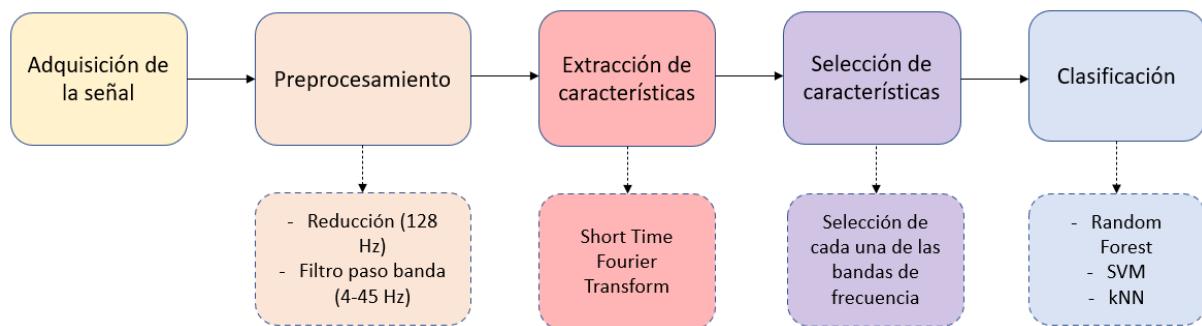


Figura 8: Metodología seguida para los experimentos 2.

En este caso, el proceso de selección de características consiste en tener en cuenta las características de cada una de las bandas de frecuencia. Atendiendo a la literatura, hemos definido los siguientes rangos de frecuencias: banda delta [1-4]Hz, banda theta [4-8]Hz, banda alpha [8-14]Hz, banda beta [14-30]Hz y banda gamma[30-50]Hz.

A partir de aquí, se clasifican las emociones en base a las etiquetas de la misma forma que se realiza en el experimento 1. En este caso, al ser un número de datos menor, sí que hemos llevado a cabo una búsqueda de hiperparámetros para cada clasificador de cada banda de frecuencia. En la Tabla 3 se encuentran recogidos los parámetros más comunes para cada una de las bandas de frecuencias del experimento binario y en Tabla 4 los parámetros para el experimento cuaternario. Como se puede observar, estos son muy parecidos al ajuste que se realizó en el experimento 2 binario, pero en este, al tener la experiencia previa hicimos un mejor ajuste, conociendo los valores que solían tomar estos datos.

En la clasificación, en caso del algoritmo Random Forest los parámetros ajustados han sido *max_depth* y *min_samples_split*, en caso de SVM el parámetro C y el kernel, y para kNN el número de vecinos y el parámetro que relaciona los pesos de los nodos. Como se puede observar, en algunos de los parámetros existen varios valores. Estos se corresponden con los distintos valores más comunes tomados por el modelo, los cuales están ordenados por número de usos.

Banda de frecuencia	Random Forest (max_depth, min_samples split)	SVM (C, kernel)	kNN (n_neighbours, weights)
Delta	5/10, 2	100, rbf	7/9. uniform
Theta	10, 2	100/10, rbf	10/9. uniform
Alfa	10, 2	100, rbf/linear	7/5/8. uniform
Beta	5/10, 2	100, rbf	7/9. uniform
Gamma	5/10, 2	100, rbf/linear	9/8. uniform

Tabla 3: Ajuste de hiperparámetros en el experimento 2 binario.

Banda de frecuencia	Random Forest (max_depth, min_samples split)	SVM (C, kernel)	kNN (n_neighbours, weights)
Delta	10/12, 2	5/25, linear/rbf	13/15/7, uniform
Theta	10/7, 2	25/5/10, rbf/linear	15/7, uniform
Alfa	12/10, 2	25/5, rbf/linear/rbf	13/15, uniform
Beta	10/12, 2	5/25, linear/rbf	15/9, uniform
Gamma	10/12, 2	25/5, linear	13/15/9, uniform

Tabla 4: Ajuste de hiperparámetros en el experimento 2 cuaternario.

6.3. Experimento 3

El tercer experimento sigue la metodología mostrada en Figura 9. La diferencia principal con el experimento anterior consiste en, una vez realizada la división en bandas de frecuencia, en vez de evaluar estas bandas por separado, unimos la información extraída de las cinco bandas en una única estructura. Anteriormente teníamos cinco estructuras de tamaño 2560x40x32. Esta vez, estamos evaluando como si nuestro EEG tuviera 160 canales (32x5). Los primeros 32 canales se corresponden con la información de la banda delta, del 33 al 64 theta, de 65 al 96 alfa, de 97 a 128 beta y de 129 a 160 gamma, como se muestra en Figura 10. Realizando esta selección, tenemos más información para posteriormente realizar la clasificación.

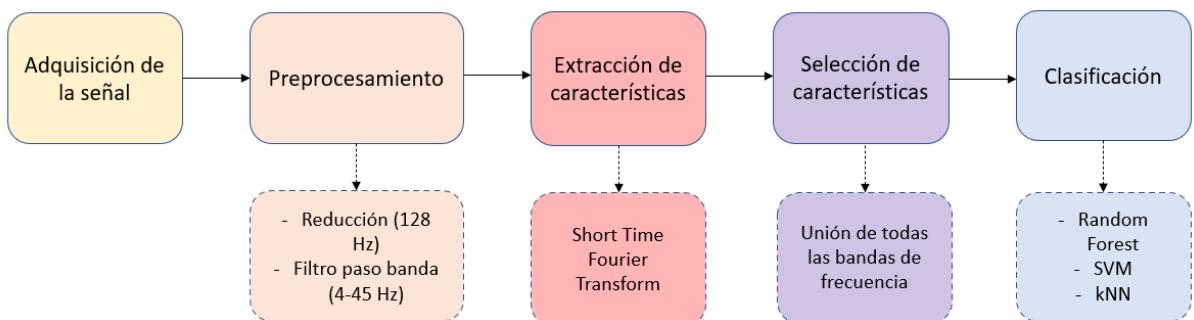


Figura 9: Metodología seguida para los experimentos 3.

En cuanto al proceso de clasificación, hemos llevado a cabo un ajuste de hiperparámetros exhaustivo para los 3 clasificadores, mostrándose Tabla 3 las combinaciones que obtuvieron

	FP1	AF3	F7	F3	FC1	FC5	T7	C3	CP1	CP5	...	C4	T8	FC6	FC2	F4	F8	AF4	Fp2	Fz	Cz
0	0.025366	0.078844	0.039507	0.094259	0.044156	0.037892	0.034969	0.148271	0.164957	0.033372	...	2.431686	0.295712	0.348758	0.779843	1.044175	0.580807	0.359518	0.834561	0.960447	0.406656
1	0.025366	0.078844	0.039507	0.094259	0.044156	0.037892	0.034969	0.148271	0.164957	0.033372	...	2.431686	0.295712	0.348758	0.779843	1.044175	0.580807	0.359518	0.834561	0.960447	0.406656
2	0.025366	0.078844	0.039507	0.094259	0.044156	0.037892	0.034969	0.148271	0.164957	0.033372	...	2.431686	0.295712	0.348758	0.779843	1.044175	0.580807	0.359518	0.834561	0.960447	0.406656
3	0.025366	0.078844	0.039507	0.094259	0.044156	0.037892	0.034969	0.148271	0.164957	0.033372	...	2.431686	0.295712	0.348758	0.779843	1.044175	0.580807	0.359518	0.834561	0.960447	0.406656
4	0.025366	0.078844	0.039507	0.094259	0.044156	0.037892	0.034969	0.148271	0.164957	0.033372	...	2.431686	0.295712	0.348758	0.779843	1.044175	0.580807	0.359518	0.834561	0.960447	0.406656
...	
2555	0.022481	0.172611	0.057046	0.109849	0.242265	0.070911	0.196101	0.334543	0.355690	0.188437	...	17.305105	0.771617	1.971791	0.788704	5.179255	3.076131	0.743108	0.665851	6.491435	1.554092
2556	0.022481	0.172611	0.057046	0.109849	0.242265	0.070911	0.196101	0.334543	0.355690	0.188437	...	17.305105	0.771617	1.971791	0.788704	5.179255	3.076131	0.743108	0.665851	6.491435	1.554092
2557	0.022481	0.172611	0.057046	0.109849	0.242265	0.070911	0.196101	0.334543	0.355690	0.188437	...	17.305105	0.771617	1.971791	0.788704	5.179255	3.076131	0.743108	0.665851	6.491435	1.554092
2558	0.022481	0.172611	0.057046	0.109849	0.242265	0.070911	0.196101	0.334543	0.355690	0.188437	...	17.305105	0.771617	1.971791	0.788704	5.179255	3.076131	0.743108	0.665851	6.491435	1.554092
2559	0.022481	0.172611	0.057046	0.109849	0.242265	0.070911	0.196101	0.334543	0.355690	0.188437	...	17.305105	0.771617	1.971791	0.788704	5.179255	3.076131	0.743108	0.665851	6.491435	1.554092

2560 rows × 160 columns

Figura 10: Estructura DataFrame con la unión de bandas de frecuencia.

Random Forest (max_depth, min_samples split)	SVM (C, kernel)	kNN (n_neighbours, weights)
10/7, 2	5/10/25, linear	9/5/15/12, uniform

Tabla 5: Ajuste de hiperparámetros en el experimento 3 binario.

mejores resultados para la clasificación binaria. Por su parte, en la tabla Tabla 6 se muestran los valores que han sido seleccionados con asiduidad durante la ejecución del experimento multiclas.

6.4. Experimento 4

En el cuarto experimento, seguimos el ciclo mostrado en Figura 11. Lo más destacable es la selección de características que se realiza, que consiste en una selección de los mejores canales. No sólo hemos realizado una selección de canales propia en la que vemos si la precisión global se deteriora mucho frente al experimento anterior, sino que también hemos realizado una selección de canales más usados en la literatura, para comparar nuestros experimentos. Estos resultados se compararán posteriormente.

Para realizar las clasificaciones de ambas selecciones, hemos realizado una búsqueda de hiperparámetros, para obtener el modelo que mejor funciona para cada uno de los clasificadores. Una vez obtenido esto, para el modelo de los algoritmos Random Forest y kNN, hemos usado la selección que nos da el atributo *feature_importances_*. En la figura Figura 12 se muestra la selección concreta que se realiza para uno de los sujetos en el experimento binario. Esta selección ha sido la que hemos realizado también para kNN, ya

Random Forest (max_depth, min_samples split)	SVM (C, kernel)	kNN (n_neighbours, weights)
10, 2	10/1, linear	9/7, uniform

Tabla 6: Ajuste de hiperparámetros en el experimento 3 cuaternario.

que el algoritmo Random Forest es muy robusto y suele realizar una selección bastante acertada, como se comprobará en la sección de resultados. En caso del algoritmo SVM, obtenemos la selección de la misma forma, pero esta vez por medio del atributo *coef_*. Para el experimento 2D, las selecciones se realizan de la misma forma.

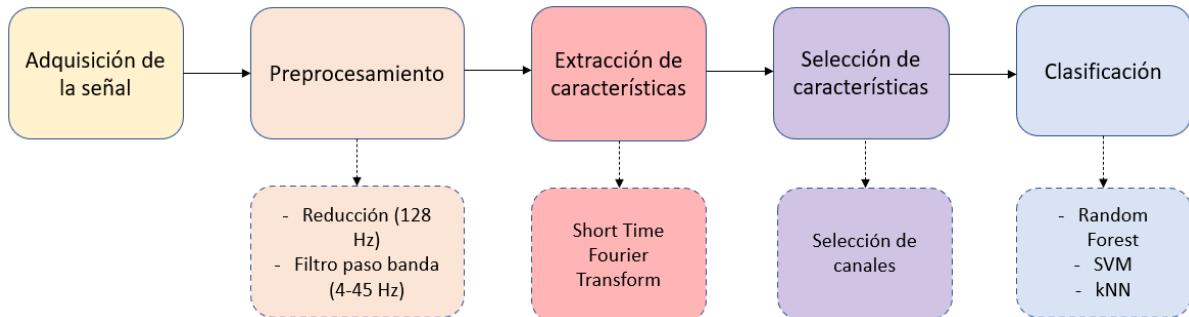


Figura 11: Metodología seguida los experimentos 4.

G-PO4	T-PO4	A-T8	B-T8	B-FC6	G-FC1	G-F3	T-T8	T-FP1	G-FC6	...	D-Oz	D-CP5	B-CP5	B-P3	D-Pz	T-F7	G-AF3	G-Fz	D-C4	B-FC5
0.069372	0.055833	0.052116	0.046995	0.043803	0.041691	0.033424	0.033324	0.026397	0.02639	...	0.020266	0.018551	0.017133	0.01639	0.016329	0.016152	0.014725	0.013101	0.011741	0.01093

Figura 12: Selección de canales del experimento 4 binario.

En este experimento también hemos realizado una búsqueda de hiperparámetros que han mejorado los resultados significativamente, como se mostrará en la siguiente sección.

7. Resultados obtenidos

Para realizar las evaluaciones de los resultados obtenidos en los experimentos vamos a utilizar dos métricas en función de qué queramos comparar. Primeramente, para comparar las distintas metodologías tanto en las clasificaciones binarias como cuaternarias, vamos a hacer uso de la métrica *f1_score* de cada una de las emociones. Esto se debe a que este valor es realmente una medida que tiene en cuenta tanto el *recall* como la precisión, por lo que será más robusta. La segunda métrica se corresponde con el valor de *accuracy*, que usaremos para comparar nuestros resultados con los encontrados en la literatura. Esta métrica no es la que mejor refleja cómo funciona un modelo, puesto que no funciona bien cuando las clases están desbalanceadas. Pero dado que es la más frecuentada en este tipo de experimentos, la necesitamos para comparar resultados.

7.1. Clasificaciones binarias

La Tabla 7 contiene los valores *score* y desviaciones típicas de cada una de las emociones binarias para cada uno de los clasificadores en cada de los cuatro experimentos. Como se puede observar a simple vista, los peores resultados para los tres clasificadores se corresponden con el primer experimento, lo cual es algo que nos podíamos esperar, al no haber extracción de características. Es destacable el hecho de que los tres clasificadores presentan una efectividad mayor para las emociones positivas, “happy”, que para las negativas, “sad”. En concreto, el algoritmo Random Forest presenta una diferencia de más de un 25 % entre ambas emociones. También es destacable el alto valor de desviación típica de los datos (13.10 % y 16.85 %). Esto indica que existe una gran variabilidad de error en las clasificaciones.

En el segundo experimento encontramos varias situaciones a destacar. En primera instancia, observamos una gran diferencia entre las precisiones de Random Forest y kNN frente a SVM en las bandas de frecuencia más bajas (Delta, Theta y Alfa). Esto se debe a que este tipo de bandas de frecuencia están más relacionadas con el estado cognitivo de los sujetos que con el estado emocional y como se puede observar, SVM no es capaz de detectar correctamente las emociones en ellas, mientras que para Random Forest y kNN la baja frecuencia no supone un problema. En las bandas superiores (Beta y Gamma) se observan precisiones por encima del 92 % para ambas emociones en todos los clasificadores.

Para el tercer experimento, en el que juntábamos todas las bandas, hemos obtenido buenas tasas de acierto de ambas emociones con los tres clasificadores. En concreto, tras realizar varios ajustes, hemos conseguido tasas de acierto superiores a 95 % para el estado “happy” y mayores a 94 % para “sad”.

Finalmente, el cuarto experimento trata de realizar una comparación de nuestra selección de canales con la realizada por la literatura. Se puede observar que, tanto los algoritmos de

Experimento	Random Forest		SVM		kNN	
	sad	happy	sad	happy	sad	happy
1	48,99 ± 13,10	74,68 ± 16,85	43,97 ± 8,52	59,57 ± 11,65	68,07 ± 8,09	76,97 ± 10,17
2 delta	94,88 ± 2,77	95,88 ± 2,01	33,90 ± 31,32	64,39 ± 22,20	93,89 ± 2,93	95,09 ± 2,12
2 theta	94,65 ± 2,94	95,74 ± 1,92	48,57 ± 31,08	72,23 ± 17,34	94,01 ± 2,77	95,20 ± 2,11
2 alfa	94,63 ± 3,01	95,73 ± 1,96	61,15 ± 25,86	76,51 ± 12,53	94,03 ± 2,98	95,20 ± 2,23
2 beta	94,49 ± 2,87	95,63 ± 1,94	93,57 ± 4,11	94,51 ± 4,89	93,92 ± 2,94	95,22 ± 1,93
2 gamma	94,58 ± 3,02	95,61 ± 2,16	92,59 ± 4,47	93,45 ± 5,74	94,18 ± 3,42	95,49 ± 1,97
3	94,82 ± 2,84	95,72 ± 1,99	94,66 ± 2,90	95,63 ± 1,90	94,28 ± 2,73	95,25 ± 1,99
4 propio	95,00 ± 3,26	95,99 ± 1,87	94,82 ± 3,30	95,81 ± 2,20	95,50 ± 1,69	95,50 ± 1,69
4 literatura	95,12 ± 2,67	95,96 ± 1,90	90,26 ± 5,60	92,03 ± 4,85	95,43 ± 1,42	95,43 ± 1,42

Tabla 7: Resumen de precisiones en cada uno de los experimentos binarios basadas en la métrica *f1_score*

Random Forest como de kNN, al realizar la misma selección de canales, obtienen valores parecidos en sus evaluaciones. En el caso de SVM, los resultados de la literatura siguen siendo muy buenos (mayor al 90 %), pero no alcanzan los de nuestra selección, que superan el 95 % de acierto.

7.2. Clasificaciones cuaternarias

En la tabla Tabla 8 podemos observar los valores de *f1-score* para la clasificación cuaternaria de emociones.

En líneas generales, los resultados son bastante parecidos a los obtenidos en los experimentos binarios. Las emociones positivas (“pleasure” y “joy”) muestran tasas de acierto superiores que las negativas (“sadness” y “anger”).

En el experimento 2, observamos una tendencia similar a lo que ocurría en las clasificaciones binarias, pero más acentuado. Los algoritmos Random Forest y kNN obtienen tasas de acierto f1 superiores al 85 % e, incluso, superiores al 90 % para todas las bandas como es el caso de la emoción “joy”. Por su parte, el algoritmo SVM sólo muestra buenos resultados cuando se evalúan las dos bandas más altas, beta y gamma.

El experimento 3 sigue la tónica de los anteriores. Como se puede observar en la tabla obtenemos una tasa de acierto con f1 entorno al 90 % para todas las emociones y los tres clasificadores, destacando en este caso las etiquetas “anger” y “joy”. Por el contrario, las emociones “sadness” y “pleasure” se quedan en torno al 88 % de acierto. Para ambos bloques de emociones son reseñables los valores de desviación típica. Mientras que para las emociones que superan el 90 % estos valores están entorno al 5 %, para las dos últimas emociones, los valores de desviación típica superan el 20 %, lo que significa más variabilidad en los resultados.

Finalmente, en el experimento 4, para Random Forest la precisión de la literatura es ligeramente inferior a la seleccionada por nosotros. En SVM sí que se aprecia un aumento significativo en nuestra selección frente a la literatura y finalmente, para kNN, se obtienen resultados con valores entorno al 90 %. Como ocurría en la clasificación binaria, hemos comprobado que una reducción de los datos mediante selección de características no implica una degradación del acierto y sí que puede mejorarlo, por lo que se mejora el rendimiento al obtener resultados similares usando menos recursos.

7.3. Comparación con literatura

En esta sección vamos a comparar la precisión de nuestros resultados con experimentos similares llevados a cabo por la literatura. Cabe destacar que no sólo buscamos que sigan la misma (o similares) metodologías de trabajo, sino que también usen los mismos datos sobre los que podamos trabajar, en este caso la DEAP como base de datos. En la Tabla 9 se muestran las precisiones de cada uno de los clasificadores para experimento como media de las precisiones de las emociones. La métrica que se usa, como se mencionó anteriormente, es *accuracy*, ya que es la métrica usada en los trabajos estudiados de la literatura.

En cuanto a trabajos previos que han usado los mismos clasificadores que en el presente trabajo, [62] obtuvo un 64.71 % de *accuracy* y un 74.94 % con la métrica *f1_score* para la clasificación de la valencia. Estos resultados están bastante alejados de nuestras clasificaciones obtenidas, mostradas en Tabla 9, donde alcanzamos más de un 90 % de acierto en evaluaciones globales con extracción de características, como son los experimentos 3 y 4.

En [74], mediante el uso de SVM se obtuvo un 62.3 % para valencia y un 56.2 % para excitación. Estos resultados son comparables con nuestros experimentos 3 y 4 binarios, ya que se realiza una fusión de los canales. En nuestro caso, evaluamos la valencia para los estados “happy”, “sad”, obteniendo tasas de precisión mayores a 95 %, con desviaciones típicas menores que dos. Esto quiere decir que nuestros resultados son bastante estables. En este artículo, los autores también hacen uso del algoritmo kNN, para el que obtienen la precisión de 60.4 % para valencia, que es un valor muy inferior a nuestro 95.05 % obtenido con el mismo clasificador en el experimento 3. Finalmente, con el algoritmo SDEL obtuvieron un 82.2 % de acierto, el cual es el modelo que mejor les funciona, pero no llega a nuestros mejores niveles de efectividad, que se encuentran en el 95.80 % y 95.81 % en el experimento 4.

En [24], cuando se evalúa usando SVM, se obtiene un 58.9 % de precisión. En este caso la clasificación que se realiza es 3D, y nosotros la mayor que realizamos es 2D, por lo que queda pendiente para futuros trabajos aumentar la dimensionalidad de los modelos propuestos y evaluarlos. Aun así, cabe destacar que nuestros resultados del experimento 3 cuaternario, aún teniendo una dimensión menos, superan en precisión por un 35 % a los de los autores.

Experimento	Random Forest						SVM						kNN					
	sadness	anger	pleasure	joy	sadness	anger	pleasure	joy	sadness	anger	pleasure	joy	sadness	anger	pleasure	joy		
2 : delta	85.77 ± 17.34	89.83 ± 6.38	88.56 ± 17.97	94.06 ± 3.74	13.45 ± 29.17	44.64 ± 42.94	39.44 ± 42.42	57.98 ± 22.10	84.35 ± 18.28	89.12 ± 6.24	87.61 ± 18.14	92.99 ± 4.79						
2 : theta	86.29 ± 17.61	89.39 ± 6.26	88.77 ± 17.94	93.78 ± 3.32	18.95 ± 33.92	46.84 ± 41.81	42.38 ± 41.96	57.37 ± 17.05	84.47 ± 17.65	88.44 ± 6.00	87.68 ± 17.99	93.05 ± 3.70						
2 : alfa	85.41 ± 17.21	89.78 ± 5.96	88.95 ± 17.97	93.90 ± 3.86	27.40 ± 37.82	57.24 ± 38.41	44.02 ± 38.71	59.21 ± 13.70	83.36 ± 18.06	87.83 ± 6.90	88.48 ± 18.07	93.68 ± 3.79						
2 : beta	86.00 ± 17.41	89.23 ± 5.95	88.31 ± 18.14	93.77 ± 3.32	85.18 ± 17.37	89.68 ± 5.91	88.56 ± 17.73	92.96 ± 3.54	85.76 ± 17.27	88.52 ± 6.10	87.25 ± 17.71	92.85 ± 3.88						
2 : gamma	85.01 ± 17.36	89.86 ± 5.89	88.85 ± 17.71	93.70 ± 3.36	85.25 ± 17.31	89.79 ± 5.95	88.35 ± 17.80	92.96 ± 3.82	85.26 ± 17.93	88.62 ± 6.48	87.87 ± 18.08	93.00 ± 3.55						
3	85.00 ± 22.71	91.57 ± 6.12	86.54 ± 22.85	92.94 ± 3.86	84.79 ± 22.58	91.58 ± 6.20	85.95 ± 22.73	93.06 ± 3.82	85.79 ± 22.94	89.21 ± 7.21	85.08 ± 22.41	92.88 ± 3.44						
4 propio	84.72 ± 17.82	89.76 ± 5.94	88.98 ± 17.84	94.04 ± 3.65	84.86 ± 17.30	88.44 ± 7.60	87.83 ± 17.92	91.41 ± 5.30	84.46 ± 18.36	87.48 ± 7.49	87.29 ± 17.77	93.14 ± 4.25						
4 literatura	85.62 ± 17.40	89.63 ± 6.15	88.20 ± 18.04	93.72 ± 3.28	75.11 ± 24.70	67.43 ± 12.50	77.37 ± 18.04	71.17 ± 9.96	84.40 ± 17.77	89.37 ± 6.62	87.21 ± 18.30	93.01 ± 4.41						

Tabla 8: Resumen de precisiones en cada uno de los experimentos cuaternarios basadas en la métrica $f1_score$

id	Random Forest	SVM	kNN
1 binario	$69,46 \pm 6,87$	$55,06 \pm 6,02$	$74,69 \pm 6,98$
2 binario : delta	$95,68 \pm 1,58$	$63,81 \pm 7,10$	$94,82 \pm 1,82$
2 binario : theta	$95,51 \pm 1,67$	$70,36 \pm 8,25$	$94,93 \pm 1,69$
2 binario : alfa	$95,50 \pm 1,74$	$74,91 \pm 8,58$	$94,96 \pm 1,80$
2 binario : beta	$95,39 \pm 1,55$	$94,42 \pm 3,70$	$94,90 \pm 1,62$
2 binario : gamma	$95,41 \pm 1,84$	$93,42 \pm 4,54$	$95,20 \pm 1,76$
3 binario	$95,60 \pm 1,59$	$95,45 \pm 1,62$	$95,05 \pm 1,64$
4 binario propio	$95,80 \pm 1,66$	$95,62 \pm 1,87$	$95,50 \pm 1,69$
4 binario literatura	$95,81 \pm 1,58$	$91,68 \pm 4,42$	$95,43 \pm 1,42$
2 cuaternario : delta	$91,25 \pm 6,29$	$50,77 \pm 8,03$	$91,58 \pm 2,03$
2 cuaternario : theta	$92,26 \pm 1,84$	$51,83 \pm 7,98$	$91,71 \pm 2,41$
2 cuaternario : alfa	$92,51 \pm 1,79$	$57,64 \pm 9,33$	$91,65 \pm 2,16$
2 cuaternario : beta	$92,23 \pm 1,88$	$91,76 \pm 2,30$	$91,43 \pm 2,18$
2 cuaternario : gamma	$92,27 \pm 1,63$	$91,76 \pm 2,11$	$91,61 \pm 1,95$
3 cuaternario	$92,71 \pm 1,65$	$92,76 \pm 1,50$	$92,07 \pm 1,77$
4 cuaternario propio	$92,41 \pm 1,77$	$90,48 \pm 3,79$	$91,27 \pm 2,38$
4 cuaternario literatura	$92,20 \pm 1,90$	$71,47 \pm 8,06$	$91,46 \pm 2,08$

Tabla 9: Resumen de precisiones en cada uno de los experimentos.

En [11], los autores utilizan SVM y kNN para realizar evaluaciones 2D con las etiquetas “valencia” y “excitación”. En este caso, al igual que en nuestros experimentos 2, 3 y 4, se han realizado búsqueda de hiperparámetros con distintos kernels y número de vecinos. En caso del algoritmo SVM se ha obteniendo un 77.4 % y 73.6 % de acierto respectivamente. Estos valores están bastante alejados de nuestros mejores resultados cuaternarios, que fueron superiores al 92 % en el experimento 3.

Como resumen más general, se pueden observar ciertas mejoras frente a los resultados de la literatura, atendiendo a la tabla que se presentaba en el estado del arte Tabla 1. Incluso mostrando distintas metodologías de trabajo, el objetivo principal de lograr un reconocimiento de emociones óptimo, se ha visto cumplido con las tasas de acierto que se muestran en Tabla 9, superando en la mayoría de ocasiones los resultados ofrecidos por la literatura en condiciones similares.

8. Conclusiones

Los sistemas BCI demuestran ser dispositivos de gran calidad para la adquisición de ondas neuronales de un sujeto. Como se ha estudiado en la literatura, existe un gran abanico de usos, desde la medicina hasta el uso recreativo. La evolución de estas interfaces y su integración en los mercados genera también que aparezcan nuevas oportunidades. Actualmente existen distintos tipos de BCI y un catálogo mucho más amplio, con distinto número de canales e incluso base de software proporcionada por los desarrolladores.

En este trabajo nos hemos centrado en el ámbito médico y de la salud para reconocer las emociones de los sujetos. Los datos con los que hemos trabajado han sido proporcionados por la base de datos DEAP [2] y hemos tratado de seguir distintas metodologías para el reconocimiento de emociones por medio de algoritmos de ML. Por una parte, hemos realizado clasificaciones binarias en las que el algoritmo Random Forest ha conseguido resultados superiores a un 95 % de precisión en tres de cuatro experimentos y tanto SVM como kNN han conseguido también resultados prometedores, superando en la mayoría de experimentos el 93 % de precisión. Por otra parte, se han llevado a cabo experimentos cuaternarios, que permiten detectar cuatro emociones. En este caso, los resultados proporcionados por Random Forest vuelven a ser los mejores, superando el 92 % de precisión. Por su parte, tanto SVM como kNN superan el 90 % en la mayoría de experimentos. La principal aportación del trabajo realizado consiste en el desarrollo de distintas metodologías de trabajo relacionadas con el ciclo de vida de una BCI, que mejoren o al menos igualen los reconocimientos de emociones llevados a cabo en la literatura.

Todo el trabajo realizado está disponible en la plataforma *GitHub* y se proporcionará a cualquiera que quiera realizar pruebas o seguir con las investigaciones sobre este caso de uso.

Como trabajo futuro, se podrían llevar a cabo investigaciones que tengan en cuenta un número más amplio de emociones, introducir nuevos métodos para extraer más características de los datos, o poner en uso estos experimentos sobre un escenario de BCI en el que las señales neuronales se capturen en vivo. Actualmente, pocos estudios implementan métodos de emoción activa para provocar emociones, como los videojuegos y los simuladores de vuelo.

En el futuro, se plantea también que la generación de conjuntos de datos utilicen métodos que provoquen emociones de forma activa, porque estas técnicas simulan mejor los eventos de la “vida real” y son más eficientes en la inducción de emociones. Sin embargo, la implementación de este tipo de estudios requiere una configuración experimental significativamente más compleja.

Glosario

AMR Average Mean Reference. 18

AR Autoregressive. 12, 18

ATV Area Tegmental Ventral. 14

BCI Brain Computer Interface. 1–3, 5, 7–9, 11–13, 17, 22, 23, 25, 30, 40

DBS Deep Brain Stimulation. 10

DFT Discrete Fourier Transform. 12

DL Deep Learning. 12, 13

ECoG Electrocorticografia. 7, 9

ECSYC Emotional Competencies Scale for Young Children. 16

EEG Electroencefalografia. 1–3, 7–9, 22, 25–27, 31, 32

FFT Fast Fourier Transform. 12, 18, 19, 21

GSR Galvanic skin resistance. 27

ICA Independent Component Analysis. 12

IEMOCAP Interactive Emotional Dyadic Motion Capture. 16

kNN k-Nearest Neighbours. 1, 4, 5, 13, 19–21, 28, 31, 33, 35–37, 39, 40

MEG Magnetoencefalografia. 9

ML Machine Learning. 1–5, 8, 12, 13, 22, 23, 25, 40

PCA Principal Component Analysis. 12, 19, 20

SAM Self-Assessment Manikin. 15, 19, 26, 28

SDEL Sparse Discriminative Ensamble Learning. 20, 37

SNA Sistema Nervioso Autonomo. 14

STFT Short-Time Fourier Transform. 4, 12, 18, 21, 27, 30

SVM Support Vector Machine. 1, 4, 5, 13, 18–21, 28, 31, 34–37, 39, 40

Referencias

- [1] Base de datos SEED. <https://bcmi.sjtu.edu.cn/home/seed/index.html>.
- [2] DEAP dataset. <https://www.eecs.qmul.ac.uk/mmv/datasets/deap/readme.html>.
- [3] Electroencefalograma de BitBrain. <https://www.bitbrain.com/blog/wet-eeg-cap>.
- [4] Emociones en el cerebro. <https://www.revistadelauniversidad.mx/download/6fdd060a-5a2f-4cb5-87c5-f0ab5b025d47>.
- [5] Lóbulos del cerebro. <https://www.caracteristicas.co/cerebro/>.
- [6] Magnetoencefalograma. <https://www.alamy.es/foto-magnetoencephalography-52984058.html>.
- [7] Representación de emociones humanas. <https://uxmind.eu/2015/04/09/evaluer-les-emotions/>.
- [8] Silla de ruedas controlada por BCI. <https://metode.es/revistas-metode-monograficos/la-conexion-maquina-humano.html>.
- [9] Sistema límbico. <https://mundopnie.com/psicologia/general/dopamina-estructuras-implicadas-y-funciones-basicas/>.
- [10] AMIT, V., NAINA, AND VINITHA. Algorithm for design of digital notch filter using simulation. *International Journal of Advanced Research in Artificial Intelligence* 2 (08 2013).
- [11] ASGHAR, M. A., KHAN, M. J., AMIN, Y., RIZWAN, M., RAHMAN, M., BADNAVA, S., MIRJAVADI, S. S., ET AL. Eeg-based multi-modal emotion recognition using bag of deep features: An optimal feature selection approach. *Sensors* 19, 23 (2019), 5218.
- [12] ATKINSON, J., AND CAMPOS, D. Improving bci-based emotion recognition by combining eeg feature selection and kernel classifiers. *Expert Systems with Applications* 47 (2016), 35–41.
- [13] BAHREINI, K., VAN DER VEGT, W., AND WESTERA, W. A fuzzy logic approach to reliable real-time recognition of facial emotions. *Multimedia Tools and Applications* 78, 14 (2019), 18943–18966.
- [14] BERICAT, E. The sociology of emotions: Four decades of progress. *Current sociology* 64, 3 (2016), 491–513.

- [15] BHATTI, A. M., MAJID, M., ANWAR, S. M., AND KHAN, B. Human emotion recognition and analysis in response to audio music using brain signals. *Computers in Human Behavior* 65 (2016), 267–275.
- [16] BIRBAUMER, N. Breaking the silence: brain–computer interfaces (bci) for communication and motor control. *Psychophysiology* 43, 6 (2006), 517–532.
- [17] BOCKBRADER, M. A., FRANCISCO, G., LEE, R., OLSON, J., SOLINSKY, R., AND BONINGER, M. L. Brain computer interfaces in rehabilitation medicine. *PM&R* 10, 9 (2018), S233–S243.
- [18] BOS, D. O., ET AL. Eeg-based emotion recognition. *The influence of visual and auditory stimuli* 56, 3 (2006), 1–17.
- [19] BRADLEY, M. M., AND LANG, P. J. Measuring emotion: the self-assessment manikin and the semantic differential. *Journal of behavior therapy and experimental psychiatry* 25, 1 (1994), 49–59.
- [20] CECOTTI, H. Spelling with non-invasive brain–computer interfaces—current and future trends. *Journal of Physiology-Paris* 105, 1-3 (2011), 106–114.
- [21] CHEN, J. X., ZHANG, P. W., MAO, Z. J., HUANG, Y. F., JIANG, D. M., AND ZHANG, Y. N. Accurate eeg-based emotion recognition on combined features using deep convolutional neural networks. *IEEE Access* 7 (2019), 44317–44328.
- [22] CLONINGER, C. R. Biology of personality dimensions. *Current Opinion in Psychiatry* 13, 6 (2000), 611–616.
- [23] CÉSAR CAVALCANTI ROZA, V., AND ADRIAN POSTOLACHE, O. Multimodal approach for emotion recognition based on simulated flight experiments. *Sensors* 19, 24 (2019).
- [24] DABAS, H., SETHI, C., DUA, C., DALAWAT, M., AND SETHIA, D. Emotion classification using eeg signals. pp. 380–384.
- [25] DUDANI, S. A. The distance-weighted k-nearest-neighbor rule. *IEEE Transactions on Systems, Man, and Cybernetics*, 4 (1976), 325–327.
- [26] EDLA, D. R., MANGALOREKAR, K., DHAVALIKAR, G., AND DODIA, S. Classification of eeg data for human mental state analysis using random forest classifier. *Procedia computer science* 132 (2018), 1523–1532.
- [27] ELFENBEIN, H. A., AND AMBADY, N. Predicting workplace outcomes from the ability to eavesdrop on feelings. *Journal of Applied Psychology* 87, 5 (2002), 963.

- [28] FRANCES, A., FIRST, M. B., AND PINCUS, H. A. *DSM-IV guidebook*. American Psychiatric Association, 1995.
- [29] GRÜBLER, G., AL-KHODAIRY, A., LEEB, R., PISOTTA, I., RICCIO, A., ROHM, M., AND HILDT, E. Psychosocial and ethical aspects in non-invasive eeg-based bci research—a survey among bci users and bci professionals. *Neuroethics* 7, 1 (2014), 29–41.
- [30] GURKOK, H., NIJHOLT, A., AND POEL, M. *Brain-Computer Interface Games: Towards a Framework*. Springer Singapore, Singapore, 2017, pp. 133–150.
- [31] HARTMANN, C. J., FLIEGEN, S., GROISS, S. J., WOJTECKI, L., AND SCHNITZLER, A. An update on best practice of deep brain stimulation in parkinson’s disease. *Therapeutic advances in neurological disorders* 12 (2019), 1756286419838096.
- [32] HOSNI, S. M., GADALLAH, M. E., BAHGAT, S. F., AND ABDELWAHAB, M. S. Classification of eeg signals using different feature extraction techniques for mental-task bci. In *2007 International Conference on Computer Engineering & Systems* (2007), IEEE, pp. 220–226.
- [33] IACOVIELLO, D., PETRACCA, A., SPEZIALETTI, M., AND PLACIDI, G. A real-time classification algorithm for eeg-based bci driven by self-induced emotions. *Computer Methods and Programs in Biomedicine* 122, 3 (2015), 293–303.
- [34] KAUR, B., SINGH, D., AND ROY, P. P. Eeg based emotion classification mechanism in bci. *Procedia computer science* 132 (2018), 752–758.
- [35] KIM, M., KIM, B. H., AND JO, S. Quantitative evaluation of a low-cost noninvasive hybrid interface based on eeg and eye movement. *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 23, 2 (2014), 159–168.
- [36] KLEINSMITH, A., AND BIANCHI-BERTHOUZE, N. Recognizing affective dimensions from body posture. In *Affective Computing and Intelligent Interaction* (Berlin, Heidelberg, 2007), A. C. R. Paiva, R. Prada, and R. W. Picard, Eds., Springer Berlin Heidelberg, pp. 48–58.
- [37] KLEINSMITH, A., FUSHIMI, T., AND BIANCHI-BERTHOUZE, N. An incremental and interactive affective posture recognition system. In *International Workshop on Adapting the Interaction Style to Affective Factors* (2005), vol. 38, pp. 378–387.
- [38] KOLODZIEJ, M., MAJKOWSKI, A., ZAPALA, D., RAK, R. J., AND FRANCUZ, P. Methods of power-band extraction techniques for bci classification. In *19th International Conference Computational Problems of Electrical Engineering* (2018), IEEE, pp. 1–4.

- [39] KUMAR, N., KHAUND, K., AND HAZARIKA, S. M. Bispectral analysis of eeg for emotion recognition. *Procedia Computer Science* 84 (2016), 31–35. Proceeding of the Seventh International Conference on Intelligent Human Computer Interaction (IHCI 2015).
- [40] LI, Y., ZHENG, W., CUI, Z., ZONG, Y., AND GE, S. Eeg emotion recognition based on graph regularized sparse linear regression. *Neural Processing Letters* 49, 2 (2019), 555–571.
- [41] LV, T., YAN, J., AND XU, H. An eeg emotion recognition method based on adaboost classifier. *2017 Chinese Automation Congress (CAC)* (2017), 6050–6054.
- [42] LÉCUYER, A., LOTTE, F., REILLY, R. B., LEEB, R., HIROSE, M., AND SLATER, M. Brain-computer interfaces, virtual reality, and videogames. *Computer* 41, 10 (2008), 66–72.
- [43] MACHADO, S., ARAÚJO, F., PAES, F., VELASQUES, B., CUNHA, M., BUDDE, H., BASILE, L. F., ANGHINAH, R., ARIAS-CARRIÓN, O., CAGY, M., ET AL. Eeg-based brain-computer interfaces: an overview of basic concepts and clinical applications in neurorehabilitation. *Reviews in the Neurosciences* 21, 6 (2010), 451–468.
- [44] MANOR, R., AND GEVA, A. B. Convolutional neural network for multi-category rapid serial visual presentation bci. *Frontiers in computational neuroscience* 9 (2015), 146.
- [45] MARNEROS, A., AND AKISKAL, H. S. *The overlap of affective and schizophrenic spectra*. Cambridge university press, 2006.
- [46] MAZUMDER, I. An analytical approach of eeg analysis for emotion recognition. In *2019 Devices for Integrated Circuit (DevIC)* (2019), IEEE, pp. 256–260.
- [47] MELLINGER, J., SCHALK, G., BRAUN, C., PREISSL, H., ROSENSTIEL, W., BIRBAUMER, N., AND KÜBLER, A. An meg-based brain–computer interface (bci). *Neuroimage* 36, 3 (2007), 581–593.
- [48] MERCADILLO, R. E., DÍAZ, J. L., AND BARRIOS, F. A. Neurobiología de las emociones morales. *Salud mental* 30, 3 (2007), 1–11.
- [49] METALLINOU, A., LEE, S., AND NARAYANAN, S. Audio-visual emotion recognition using gaussian mixture models for face and voice. In *2008 Tenth IEEE International Symposium on Multimedia* (2008), pp. 250–257.
- [50] MIRANDA, E. R. Brain-computer music interface for composition and performance. *International Journal on Disability and Human Development* 5, 2 (2006), 119–126.

- [51] MURUGAPPAN, M., RIZON, M., NAGARAJAN, R., YAACOB, S., ZUNAIDI, I., AND HAZRY, D. Eeg feature extraction for classifying emotions using fcm and fkm. *International journal of Computers and Communications* 1, 2 (2007), 21–25.
- [52] MUSK, E., ET AL. An integrated brain-machine interface platform with thousands of channels. *Journal of medical Internet research* 21, 10 (2019), e16194.
- [53] MYERS, D. G., AND DEWALL, C. N. Psychology, 2004.
- [54] NICOLAS-ALONSO, L. F., AND GOMEZ-GIL, J. Brain computer interfaces, a review. *sensors* 12, 2 (2012), 1211–1279.
- [55] NIEDERMEYER, E., AND DA SILVA, F. L. *Electroencephalography—Basic principles, clinical applications, and related fields*. Urban & Schwarzenberg,, 2020.
- [56] ÖZERDEM, M. S., AND POLAT, H. Emotion recognition based on eeg features in movie clips with channel selection. *Brain informatics* 4, 4 (2017), 241–252.
- [57] PANE, E. S., WIBAWA, A. D., AND PUMOMO, M. H. Channel selection of eeg emotion recognition using stepwise discriminant analysis. In *2018 International Conference on Computer Engineering, Network and Intelligent Multimedia (CENIM)* (2018), pp. 14–19.
- [58] PANOURAS, K. J., HADJILEONTIADIS, L. J., AND PANAS, S. M. Brain-computer interface (bci): types, processing perspectives and applications. In *Multimedia services in intelligent environments*. Springer, 2010, pp. 299–321.
- [59] RAHMAN, M. A., HAQUE, M. M., ANJUM, A., MOLLAH, M. N., AND AHMAD, M. Classification of motor imagery events from prefrontal hemodynamics for bci application. In *Proceedings of International Joint Conference on Computational Intelligence* (2020), Springer, pp. 11–23.
- [60] ROJAS, D. A., GÓNGORA, L. A., AND RAMOS, O. L. Eeg signal analysis related to speech process through bci device emotiv, fft and statistical methods. *Arpn J Eng and App Sci* 11, 5 (2016), 3074–3080.
- [61] RUAN, J., WU, X., ZHOU, B., GUO, X., AND LV, Z. An automatic channel selection approach for ica-based motor imagery brain computer interface. *Journal of medical systems* 42, 12 (2018), 1–13.
- [62] SHAHZNAZ, C., SHOAIB-BIN-MASUD, AND HASAN, S. Emotion recognition based on wavelet analysis of empirical mode decomposed eeg signals responsive to music videos. *2016 IEEE Region 10 Conference (TENCON)* (2016), 424–427.

- [63] SHAW, L., AND ROUTRAY, A. Statistical features extraction for multivariate pattern analysis in meditation eeg using pca. In *2016 IEEE EMBS International Student Conference (ISC)* (2016), IEEE, pp. 1–4.
- [64] SHOVON, T. H., AL NAZI, Z., DASH, S., AND HOSSAIN, M. F. Classification of motor imagery eeg signals with multi-input convolutional neural network by augmenting stft. In *2019 5th International Conference on Advances in Electrical Engineering (ICAEE)* (2019), IEEE, pp. 398–403.
- [65] SOARES, A. P., PINHEIRO, A. P., COSTA, A., FRADE, C. S., COMESAÑA, M., AND PUREZA, R. Affective auditory stimuli: Adaptation of the international affective digitized sounds (iads-2) for european portuguese. *Behavior research methods* 45, 4 (2013), 1168–1181.
- [66] SPITZER, R. L., WILLIAMS, J. B., AND SKODOL, A. E. Dsm-iii: the major achievements and an overview. *The American Journal of Psychiatry* (1980).
- [67] SUHAIMI, N. S., MOUNTSTEPHENS, J., AND TEO, J. Eeg-based emotion recognition: A state-of-the-art review of current trends and opportunities. *Computational Intelligence and Neuroscience* 2020 (2020).
- [68] TAN, D., AND NIJHOLT, A. Brain-computer interfaces and human-computer interaction. In *Brain-Computer Interfaces*. Springer, 2010, pp. 3–19.
- [69] TANG, J., LIU, Y., HU, D., AND ZHOU, Z. Towards bci-actuated smart wheelchair system. *Biomedical engineering online* 17, 1 (2018), 1–22.
- [70] THAMMASAN, N., MORIYAMA, K., FUKUI, K.-I., AND NUMAO, M. Familiarity effects in eeg-based emotion recognition. *Brain informatics* 4, 1 (2017), 39–50.
- [71] TORRES P, E. P., TORRES, E. A., HERNÁNDEZ-ÁLVAREZ, M., YOO, S. G., ET AL. Eeg-based bci emotion recognition: A survey. *Sensors* 20, 18 (2020), 5083.
- [72] TRUEBA ATIENZA, C. La teoría aristotélica de las emociones. *Signos filosóficos* 11, 22 (2009), 147–170.
- [73] TURNER, J. H., ET AL. *Human emotions: A sociological theory*. Taylor & Francis, 2007.
- [74] ULLAH, H., UZAIR, M., MAHMOOD, A., ULLAH, M., KHAN, S. D., AND CHEIKH, F. A. Internal emotion classification using eeg signal with sparse discriminative ensemble. *IEEE Access* 7 (2019), 40144–40153.
- [75] WEI, W.-J. Development and evaluation of an emotional lexicon system for young children. *Microsystem Technologies* (2019), 1–10.

- [76] YAN, J., CHEN, S., AND DENG, S. A eeg-based emotion recognition model with rhythm and time characteristics. *Brain informatics* 6, 1 (2019), 1–8.
- [77] ZANDER, T. O., AND KOTHE, C. Towards passive brain-computer interfaces: applying brain-computer interface technology to human-machine systems in general. *Journal of neural engineering* 8, 2 (2011), 025005.
- [78] ZHANG, W., WANG, F., JIANG, Y., XU, Z., WU, S., AND ZHANG, Y. Cross-subject eeg-based emotion recognition with deep domain confusion. In *ICIRA* (2019).
- [79] ZHANG, Z. Artificial neural network. In *Multivariate time series analysis in climate and environmental research*. Springer, 2018, pp. 1–35.